2023 Python程序设计大作业：租房数据分析

1. 数据抓取

页面分析

通过谷歌浏览器提供的开发者工具，能找到租房信息的网页html中有我们所需要爬取的信息,并且都位于一个div元素下 `<div class="content__list"></div>`

所以我们可以通过这种XPath路径进行爬取，`response.xpath("//*[@id='content']/div[1]/div[1]/*")`

因长度过大，选择插入链接

然后通过静态和动态调试，能够发现我们正确获取的所需要的信息，其中一个模块如下

```
<div class="content__list--item"
data-el="listItem"
data-house_code="580191"
data-brand_code="200306015473"
data-ad_code="92217242489341624"
data-c_type="1"
data-position="1"
data-total="66377"
data-fb_expo_id="786707837408985089"
data-t="default"
data-strategy_id=""
data-click_position="1"
data-ad_type="250"
data-bid_version="v92217577549218912"
data-distribution_type="203500000002"
>
<a class="link" target="_blank" data-id="580191" href="/apartment/66276.html">
<!-- 左边图片 -->
<a
class="content__list--item--aside" target="_blank"
href="/apartment/66276.html"
title="独栋·自隅青年公寓 程远公寓 豪华开间 开间">
  <img
  alt="独栋·自隅青年公寓 程远公寓 豪华开间 开间_程远大厦租房"
  src="https://s1.ljcdn.com/matrix_pc/dist/pc/src/resource/default/250-182.png?
_v=20231122104722f2f"
  data-src="https://image1.ljcdn.com/wanjia/21363289d06c57ec84b060c24f7d72ba-
1693296506006/b95470325b1577cd5d8a79aa43ec8a87.jpg.250x182.jpg"
  class="lazyload">
  <!-- 是否展示vr图片 -->
          <!-- 广告标签 -->
      </a>
<!-- 右边内容 -->
<div class="content__list--item--main">
<!-- title -->
```

```
<p class="content__list--item--title twoline">
  <a target="_blank" href="/apartment/66276.html">
    独栋·自隅青年公寓 程远公寓 豪华开间 开间        </a>
</p>
<!-- house info -->
<p class="content__list--item--des">
            <span class="room__left">仅剩5间</span>
    <i>/</i>
          22.00-32.00㎡
  <i>/</i>5间在租        <i>/</i>
  1室0厅1卫      </p>
<!-- tags -->
<p class="content__list--item--bottom oneline">
            <i class="content__item__tag--authorization_apartment">独栋公寓</i>
            <i class="content__item__tag--rent_period_month">月租</i>
            <i class="content__item__tag--decoration">精装</i>
            <i class="content__item__tag--open_kitchen">开放厨房</i>
        </p>
<!-- brand -->
<p class="content__list--item--brand oneline">
            <span class="brand">
      自隅青年公寓          </span>
          <span class="content__list--item--time">14天前维护</span>
</p>
<!-- gr -->
      <!-- price -->
<span class="content__list--item-price"><em>4700-5200</em> 元/月</span>
</div>
</a>
</div>
```

通过谷歌浏览器开发者工具提供的XPath复制和查找功能，我们可以找到我们所需要的信息的XPath路径。

这样创建几个对应的item，就可以将数据存储到对应的item中，然后再通过pipelines.py中的代码，将数据存储到对应的csv文件中。

代码编写

1. 爬虫代码

使用之前的python爬虫框架，重新编写了5个爬虫（分别对应北京，上海，广州，深圳，以及郑州5个城市），并且将爬虫的代码进行了封装，使得代码更加简洁，易于阅读。

下面以bj代码为例，进行说明：

```
import scrapy

from test1.items import Test1Item  # 从items.py中引入MyItem对象


class LianjiaSpider(scrapy.Spider):
```

```
    name = 'bj'
    allowed_domains = ['bj.lianjia.com']
    # https://bj.lianjia.com/zufang/pg2/
    base_url = 'https://bj.lianjia.com/zufang/'


    maxpage = 200
    # 最大爬取页数

    def __init__(self, **kwargs):
        super().__init__(**kwargs)
        self.download_delay = 1
        with open("bj.txt", "r") as f:
            # 读取上次爬取的页数
            self.begin_index = int(f.read())
            self.page_index=self.begin_index
            self.start_urls = [self.base_url + "pg" + str(self.begin_index)]
            print(self.begin_index)
            f.close()
        with open("bj.txt","w") as f:
            # 更新爬取的页数
            f.write(str(self.begin_index+self.maxpage))
            f.close()

    def parse(self, response, **kwargs):
        for each in response.xpath("//*[@id='content']/div[1]/div[1]/*"):
            item = Test1Item()
            item['price'] = each.xpath("div/span/em/text()").extract_first()
            if '-' in item['price']:
                temp = item['price'].split("-")
                item['price'] = (float(temp[0]) + float(temp[1])) / 2
            temp = each.xpath("div/p[1]/a/text()").extract_first()
            # 从temp中提取数据
            temp = temp.split(" ")
            item['name'] = temp[0]
            item["house_type"] = ""
            item["area"] = ""
            item["direct"] = ""
            item["name_chinese"] = "北京"
            for i in temp:
                if '室' in i or '厅' in i or '卫' in i:
                    item['house_type'] = i
                if '东' in i or '南' in i or '西' in i or '北' in i:
                    if len(i) < 5:
                        item['direct'] = i
            temp = each.xpath("div/p[2]/text()").extract()
            for i in temp:
                if '㎡' in i:
                    i = i.replace("㎡", "").replace(" ", "").replace("\n", "")
                    if "-" in i:
                        temp = i.split("-")
                        item['area'] = (float(temp[0]) + float(temp[1])) / 2
                    else:
                        item['area'] = i
```

```
            item["block"]=each.xpath("div/p[2]/a[2]/text()").extract_first()
            print(item["block"])
            if item['price'] and item['name'] and item['house_type'] and
item['area'] and item['direct'] and item["block"]:
                yield item
        self.page_index += 1
        if self.page_index > self.maxpage+self.begin_index-1:
            return
        url=self.base_url+"pg"+str(self.page_index)

        print(url)

        yield scrapy.Request(url, callback=self.parse)
        # 递归爬取下一页
```

通过一个bj.txt文件，记录上次爬取的页数，然后通过递归爬取下一页的方式，实现了爬取多页的功能。这样在多次爬取时只需要修改爬虫的名字和pipe中输出的文件名就能实现多个城市的爬取。

2. 数据处理代码

在pipelines.py中，我们对数据进行了处理，将数据存储到对应的csv文件中。

```
import json
import csv
class Test1Pipeline:

    def open_spider(self, spider):
        try:
            self.file = open('zz.csv', "a", encoding="utf-8-sig", newline='')#这里
的zz表示郑州，可以修改为其他城市的名字
            self.writer = csv.writer(self.file)
        except Exception as err:
            print(err)

    def process_item(self, item, spider):
        list_item = [item['name_chinese'], item['block'],item['house_type'],
item['direct'], item['area'], item['price']]
        self.writer.writerow(list_item)
        return item
    def close_spider(self, spider):
            self.file.close() #关闭文件
```

3. 运行代码

在main.py中，我们通过调用execute函数，运行爬虫代码。

```
from scrapy import cmdline
cmdline.execute("scrapy crawl zz".split())
```

2. 数据获取

运行代码

为防止爬取大量数据时，被网站封禁，我们将爬取的数据分为多次爬取，每次爬取300-500页，然后将爬取的数据存储到对应的csv文件中。

发现问题

本来以为爬取的数据量不会很大，但是在爬取的过程中，发现了一些问题：

开始通过chorme浏览器发现https://bj.lianjia.com/zufang/pg1233/这个网页是存在的，但是通过爬虫爬取时，发现这个网页中的数据很不友好，实际上是重复的，这就很让人头疼。

想到的解决方法是重写一下parse函数，对每个区进行遍历，后面发现对区进行遍历都不甚足够，所以改为对板块进行遍历，由于板块较多，为了不修改代码框架，所以另写一个爬虫，将板块的数据爬取下来，然后再通过板块的数据进行遍历，这样就能够爬取到所有的数据了。

```
filename="tool.txt"
        with open(filename, "a") as f:
            for each in response.xpath("//*[@id='filter']/ul[4]/*"):  # 遍历可选的
板块
                data_id = each.xpath("@data-id").extract_first()
                if data_id is None or data_id == "0":  # 板块选项的第一个是不限，跳
过
                    continue
                newblock = each.xpath("a/@href").extract_first()
                newblock = newblock.replace("/zufang/", "").replace("/", "")
                if newblock not in self.out_list:
                    self.out_list.append(newblock)
                    f.write("\""+newblock +"\",")
            if self.num<len(self.zone_list):
                url = self.base_url + self.zone_list[self.num] + "/pg1"
                self.num=self.num+1
                yield scrapy.Request(url, callback=self.parse)
```

3. 总体房租情况比较

代码编写

这里使用jupyter进行编写，因为能方便的进行输出，以及进行数据的可视化。看起来会舒服许多许多 不过缺点是有点长了，所以这里仅仅加入一个引用的代码总体和户型

结果展示

总体房价如下图所示，能看到不同城市的数据有很大差别，参考平均数或者中位数的话，能发现深圳的房价最高，郑州的房价最低，

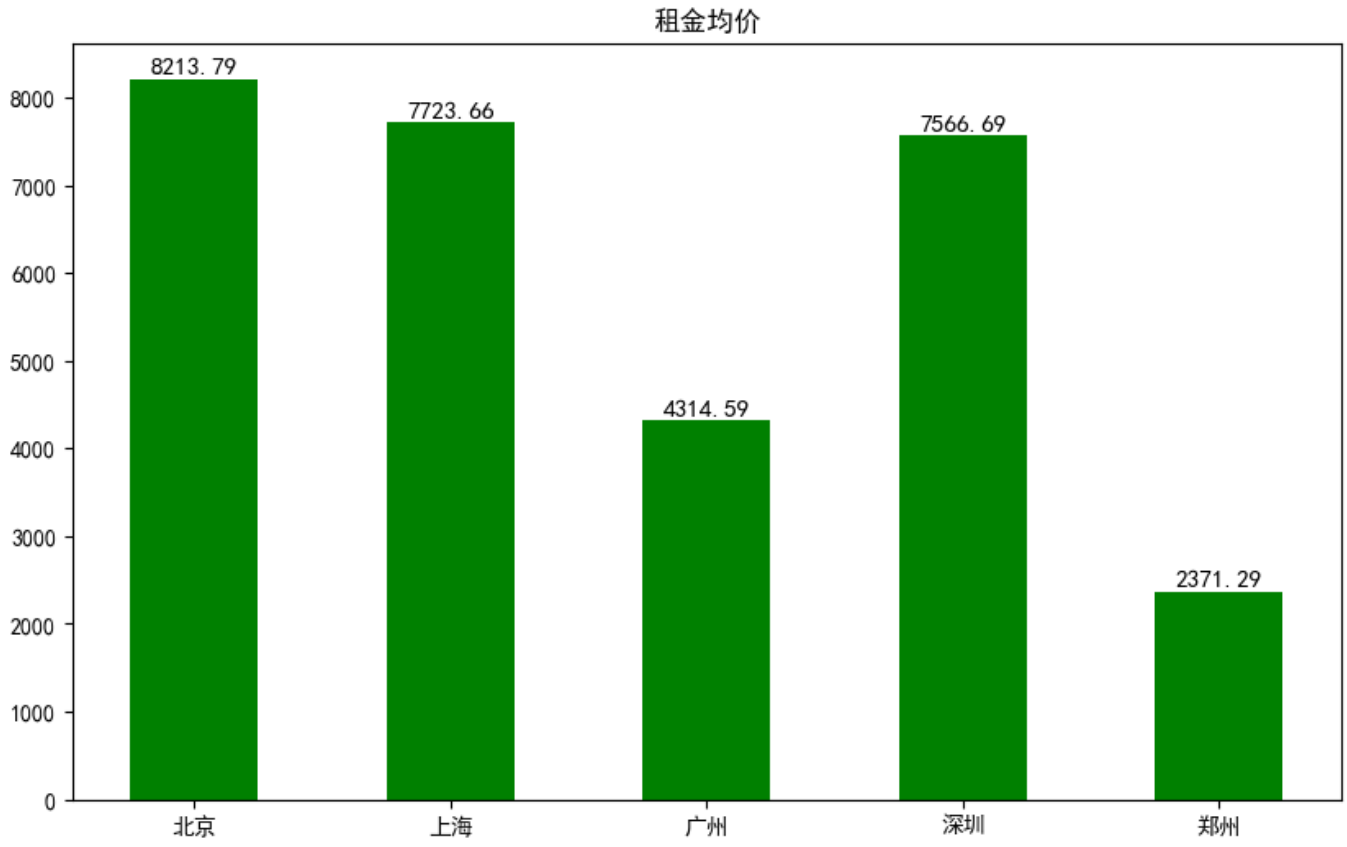
租金均价
8213.79
7723.66
4314.59
7566.69
2371.29
8000
7000
6000
5000
4000
3000
2000
1000
0
北京
上海
广州
深圳
郑州

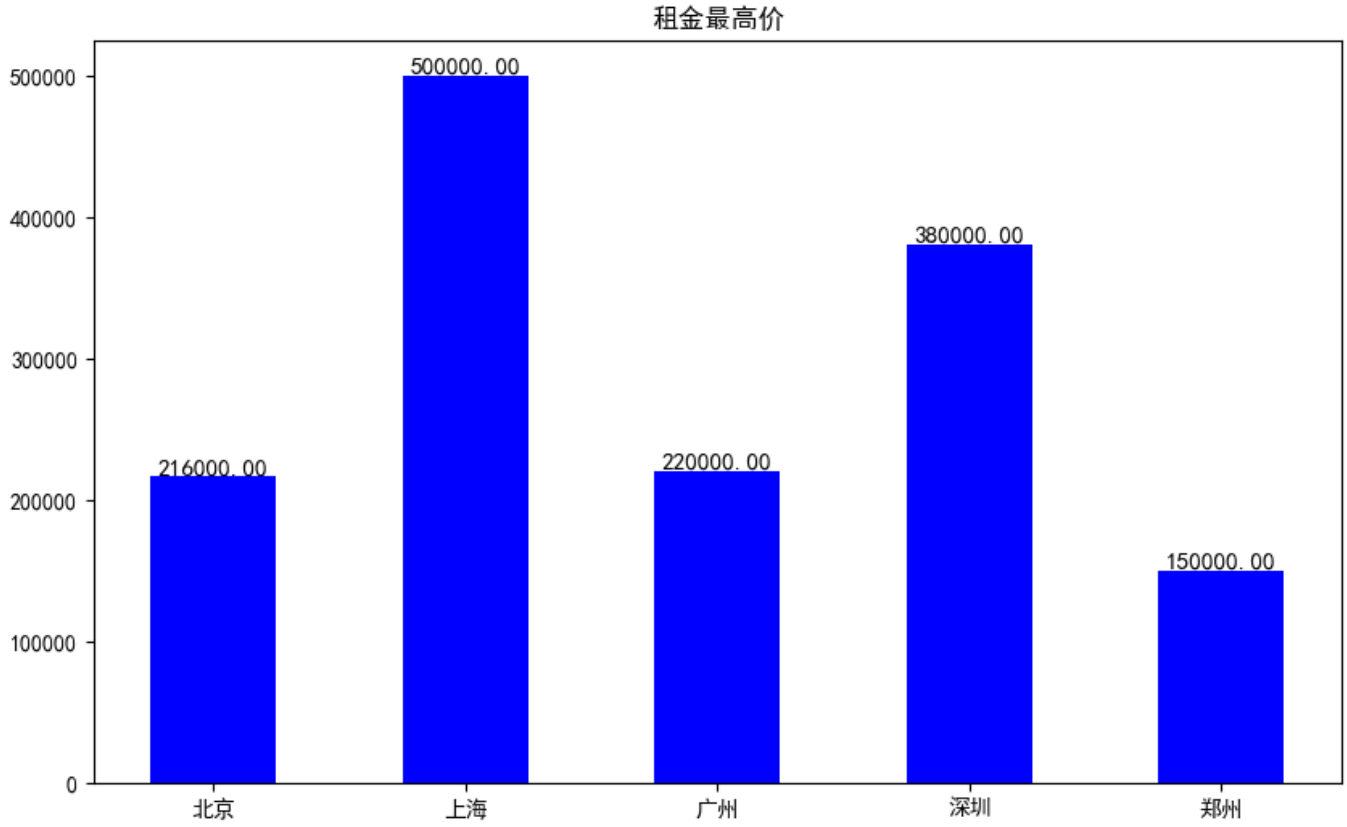
租金最高价
500000.00
216000.00
220000.00
380000.00
150000.00
500000
400000
300000
200000
100000
0
北京
上海
广州
深圳
郑州

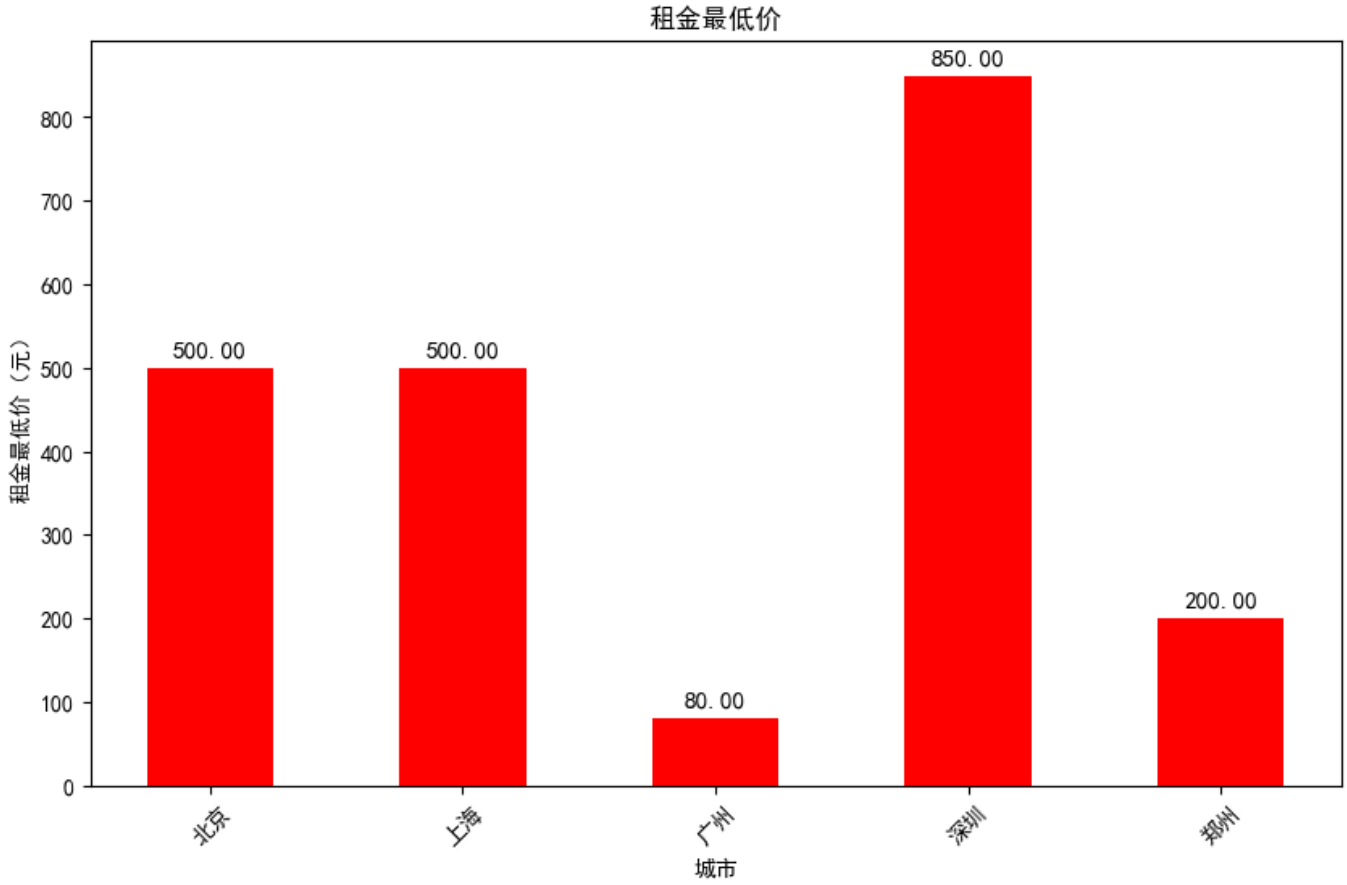
租金最低价
850.00
500.00
500.00
80.00
200.00
800
700
600
500
400
300
200
100
0
租金最低价（元）
北京
上海
广州
深圳
郑州
城市

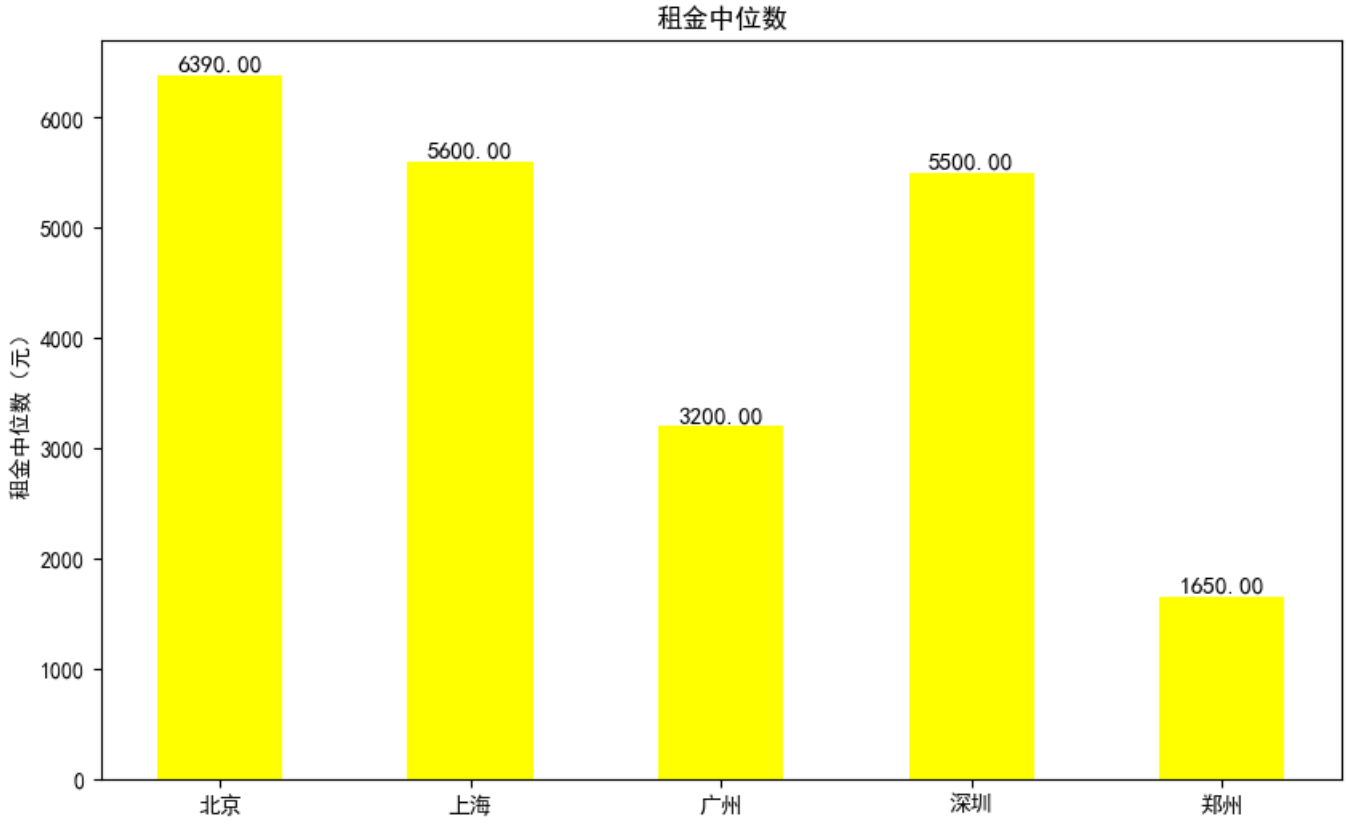
租金中位数
6390.00
5600.00
3200.00
5500.00
1650.00
6000
5000
4000
3000
2000
1000
0
租金中位数（元）
北京
上海
广州
深圳
郑州

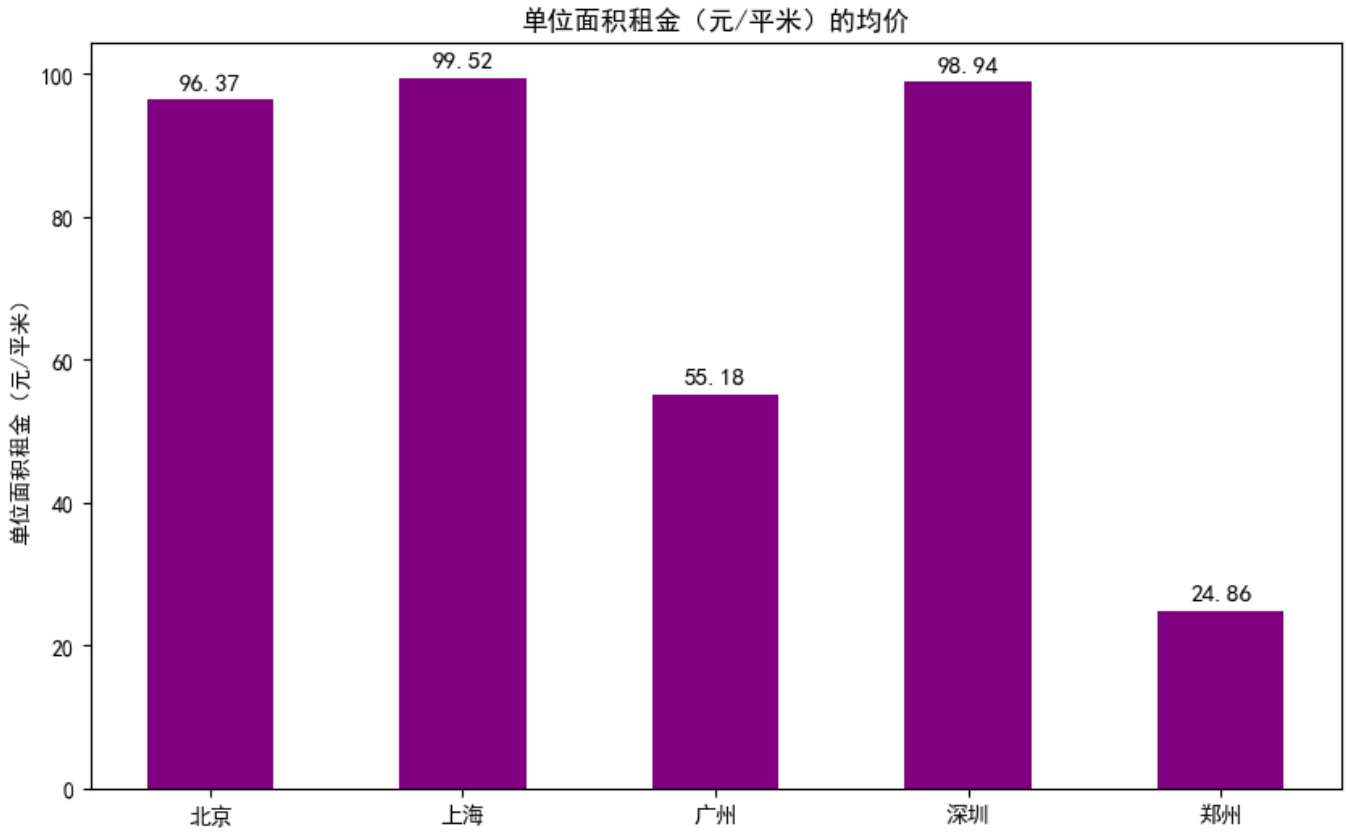

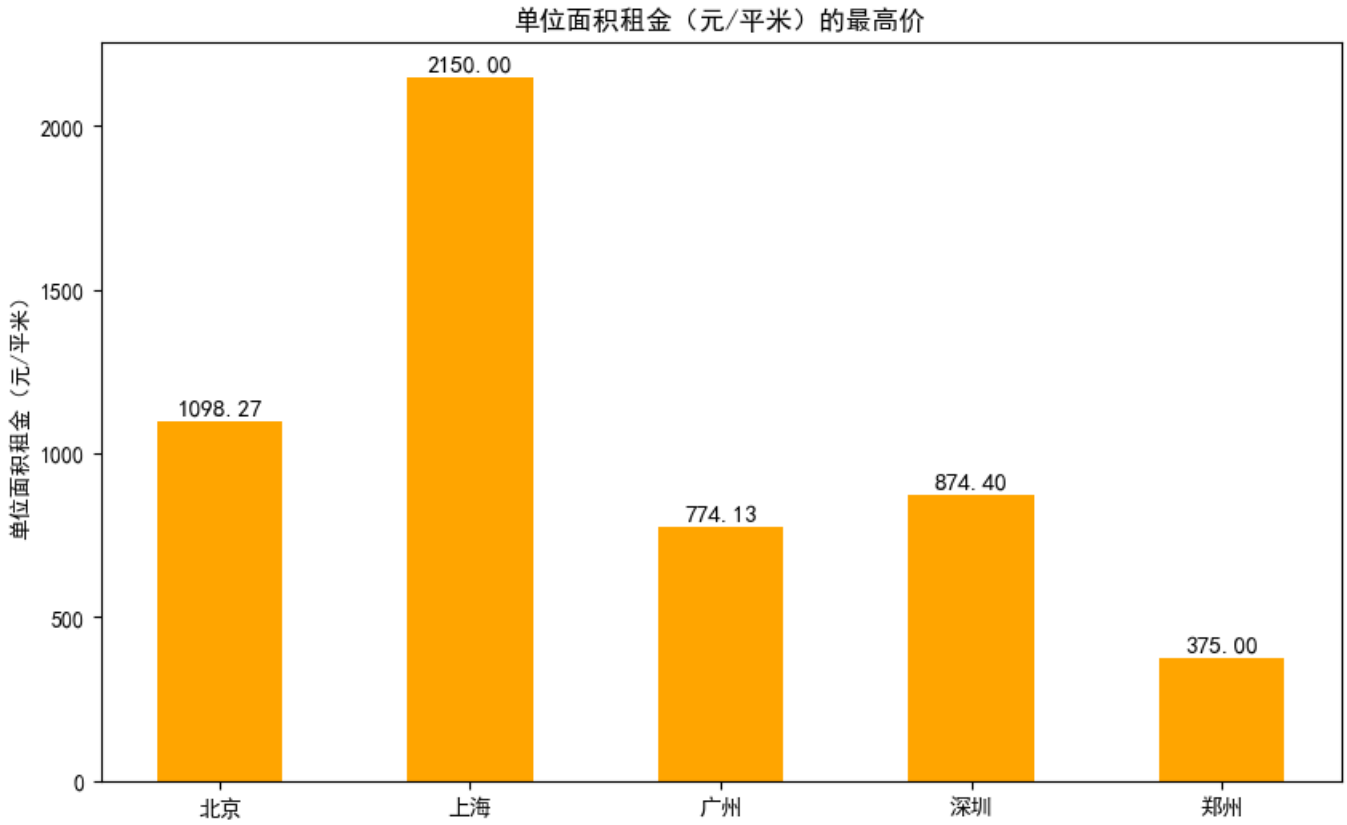

广州的数据十分奇怪，能看到极低的最低价，经查找后发现并非是因为爬取错误导致的，也没有必要去除特殊值。

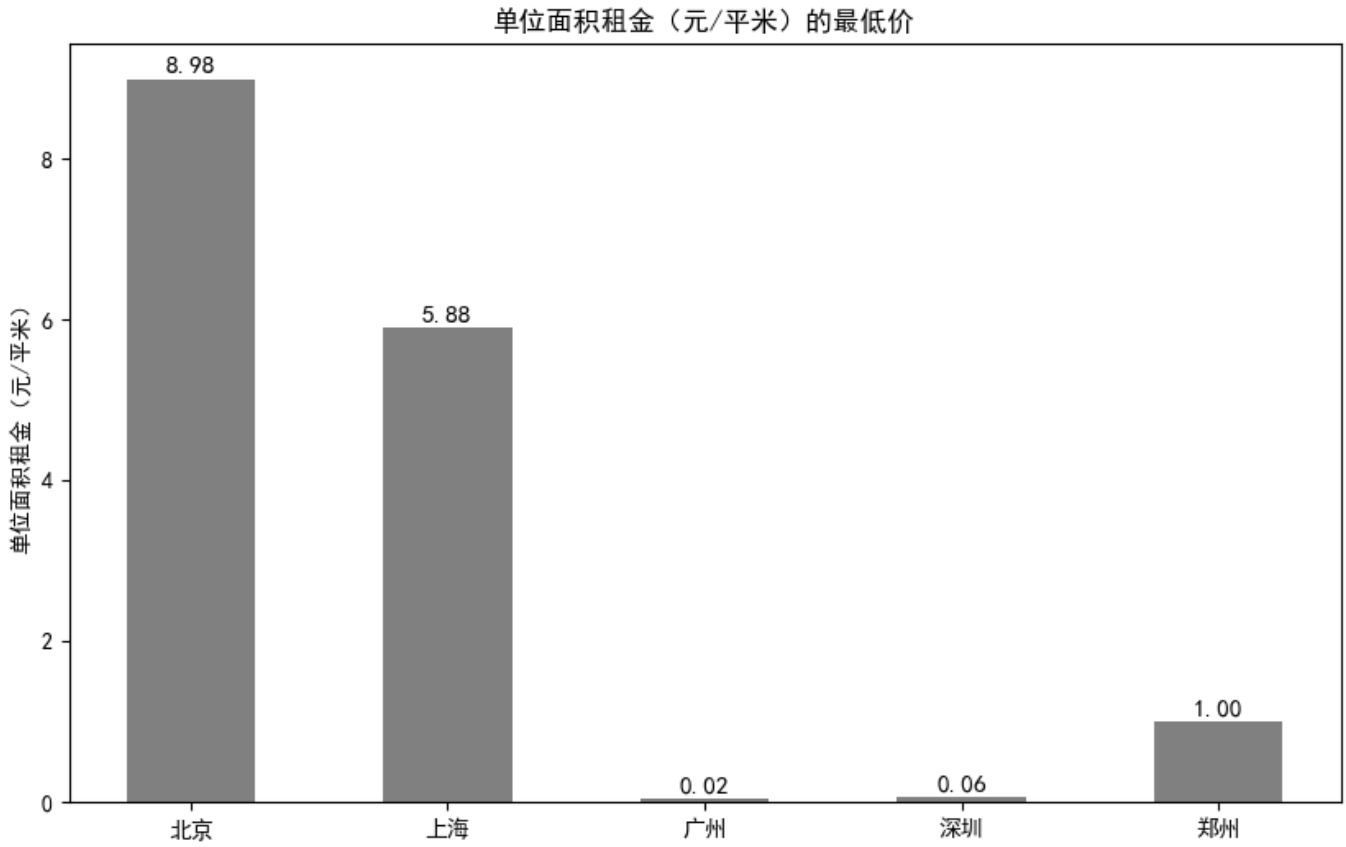

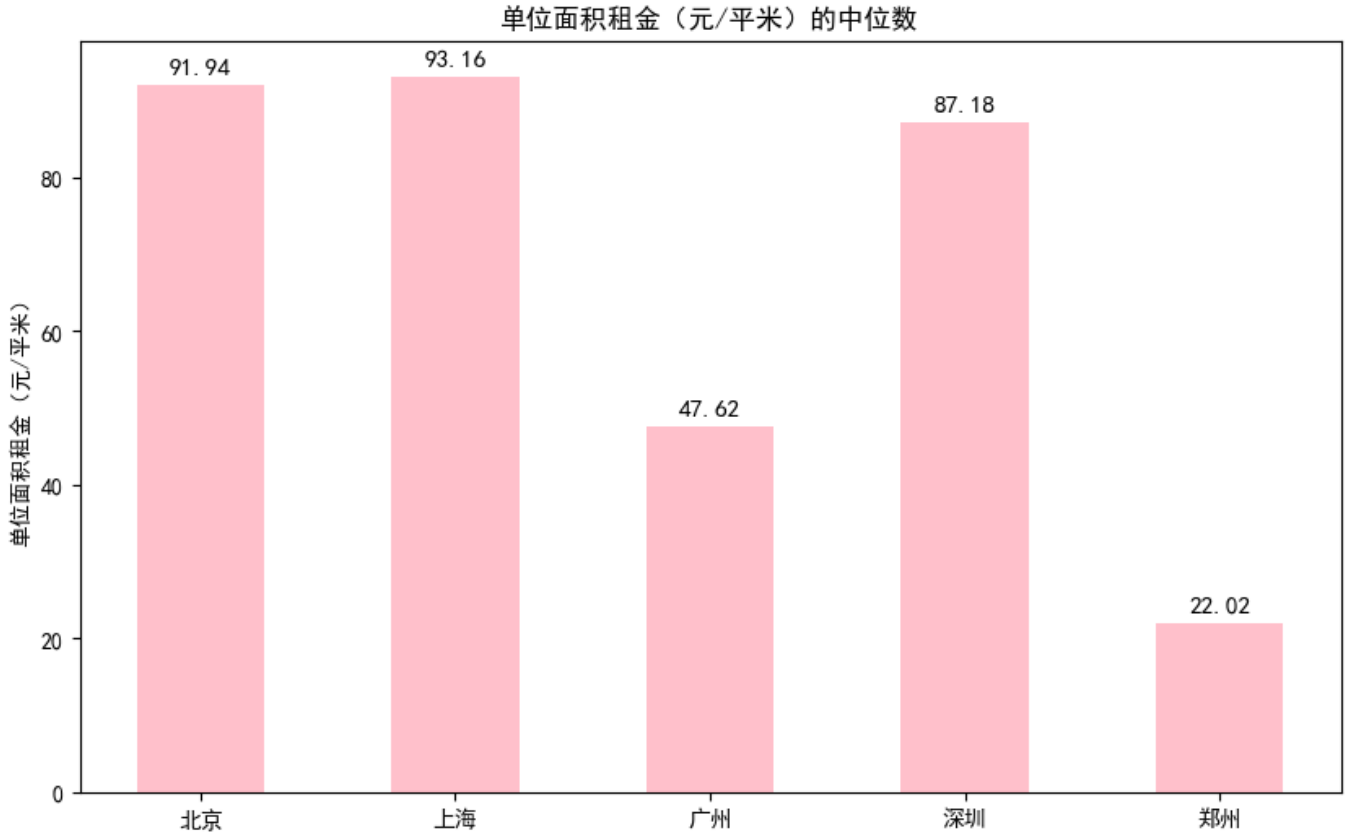

4. 不同户型比较

比较5个城市一居、二居、三居的情况，包含均价、最高价、最低价、中位数等信息，采用合适的图或表形式进行展示。

代码编写

与上面的代码类似，这里仅仅加入一个引用的代码总体和户型 同时部分代码展示如下

```
plt.figure(figsize=(10, 6))
plt.bar(result.keys(), [result[i]["租金的最高价"] for i in result.keys()],
width=0.5,color="blue")
#对每个柱子进行标注
for a,b in zip(result.keys(), [result[i]["租金的最高价"] for i in result.keys()]):
    plt.text(a, b+15, '%.2f' % b, ha='center', va= 'bottom',fontsize=11)
plt.title("租金最高价")
plt.show()
```

对户型的转化处理，将不属于123居的户型数据丢弃掉

```
for i in range(len(citynamelist)):
    df_list[i]["house_type"]=df_list[i]["house_type"].apply(get_house_type)
    df_list[i]=df_list[i].drop(df_list[i][df_list[i]["house_type"]>3].index)
    df_list[i]=df_list[i].drop(df_list[i][df_list[i]["house_type"]<1].index)
    df_list[i]=df_list[i].dropna()
    df_list[i]=df_list[i].drop_duplicates()
    df_list[i]=df_list[i].reset_index(drop=True)
    print(citynamelist_chinese[i]+"的数据数量为：",len(df_list[i]))

北京的数据数量为： 34705
上海的数据数量为： 25714
广州的数据数量为： 42807
深圳的数据数量为： 16220
郑州的数据数量为： 19014
```

结果展示

下面是不同户型的数据，能看到不同城市的数据有很大差别，参考平均数或者中位数的话，能发现大部分城市都是三居价格最高，但是单位面积价格一居最高。

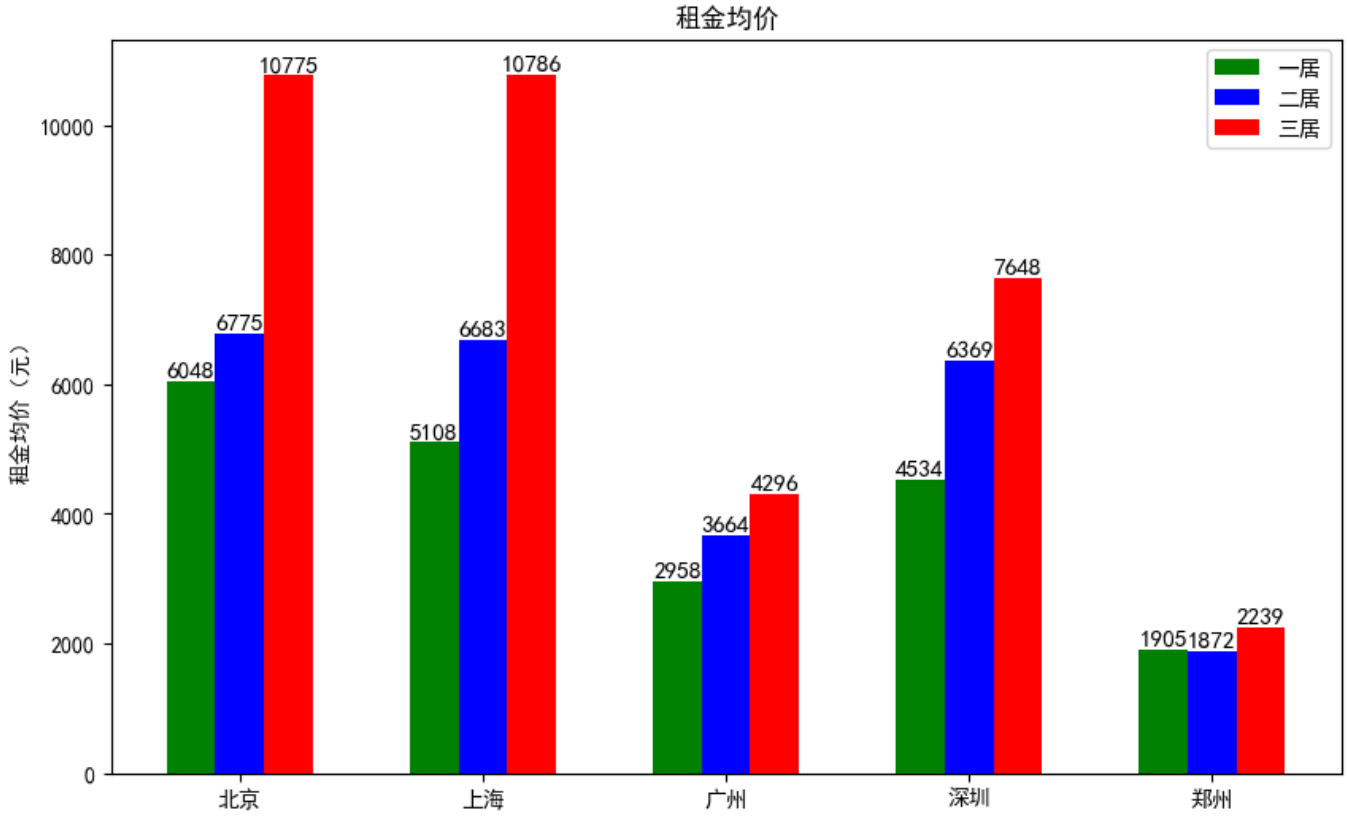
租金均价
一居
二居
三居
租金均价（元）
0
2000
4000
6000
8000
10000
6048
6775
10775
5108
6683
10786
2958
3664
4296
4534
6369
7648
1905
1872
2239
北京
上海
广州
深圳
郑州

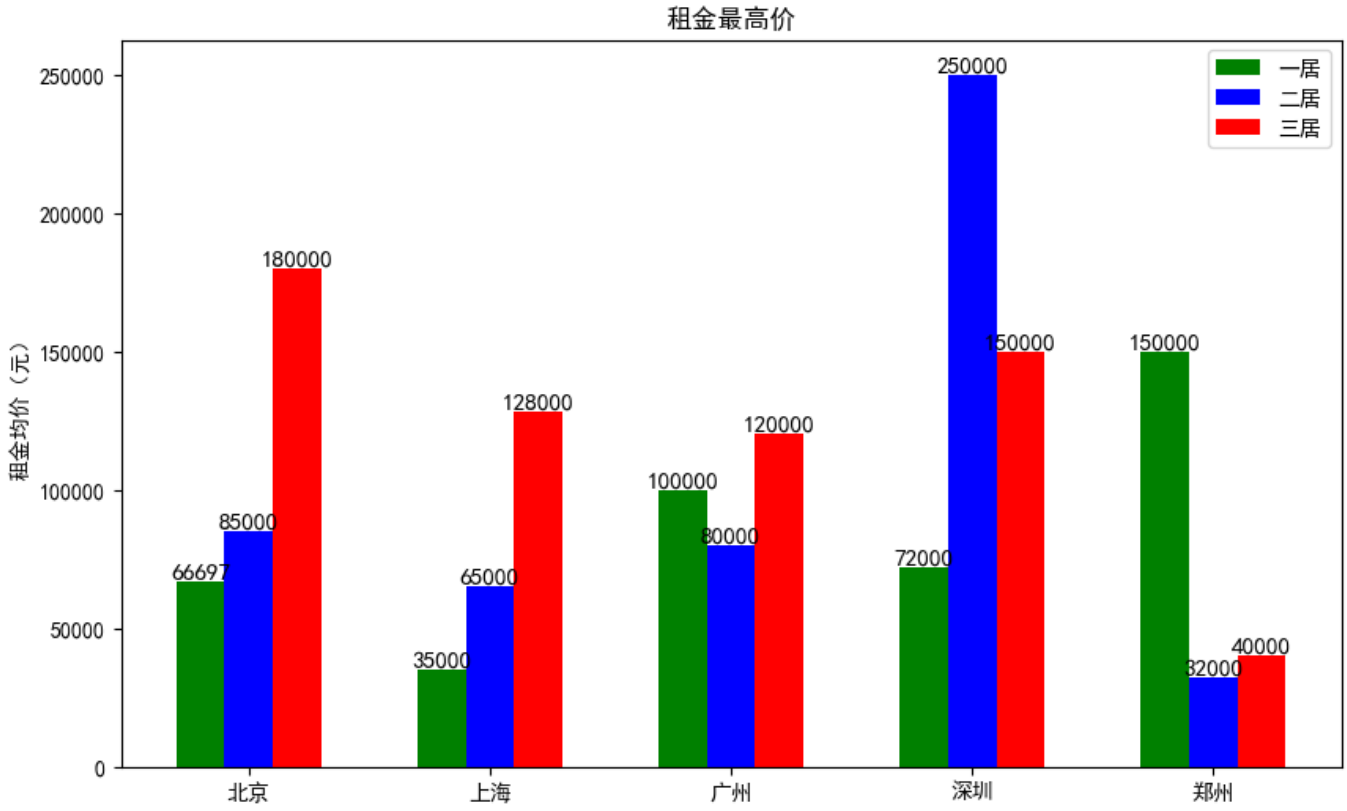
租金最高价
一居
二居
三居
租金均价（元）
0
50000
100000
150000
200000
250000
66697
85000
180000
35000
65000
128000
100000
80000
120000
72000
250000
150000
150000
32000
40000
北京
上海
广州
深圳
郑州

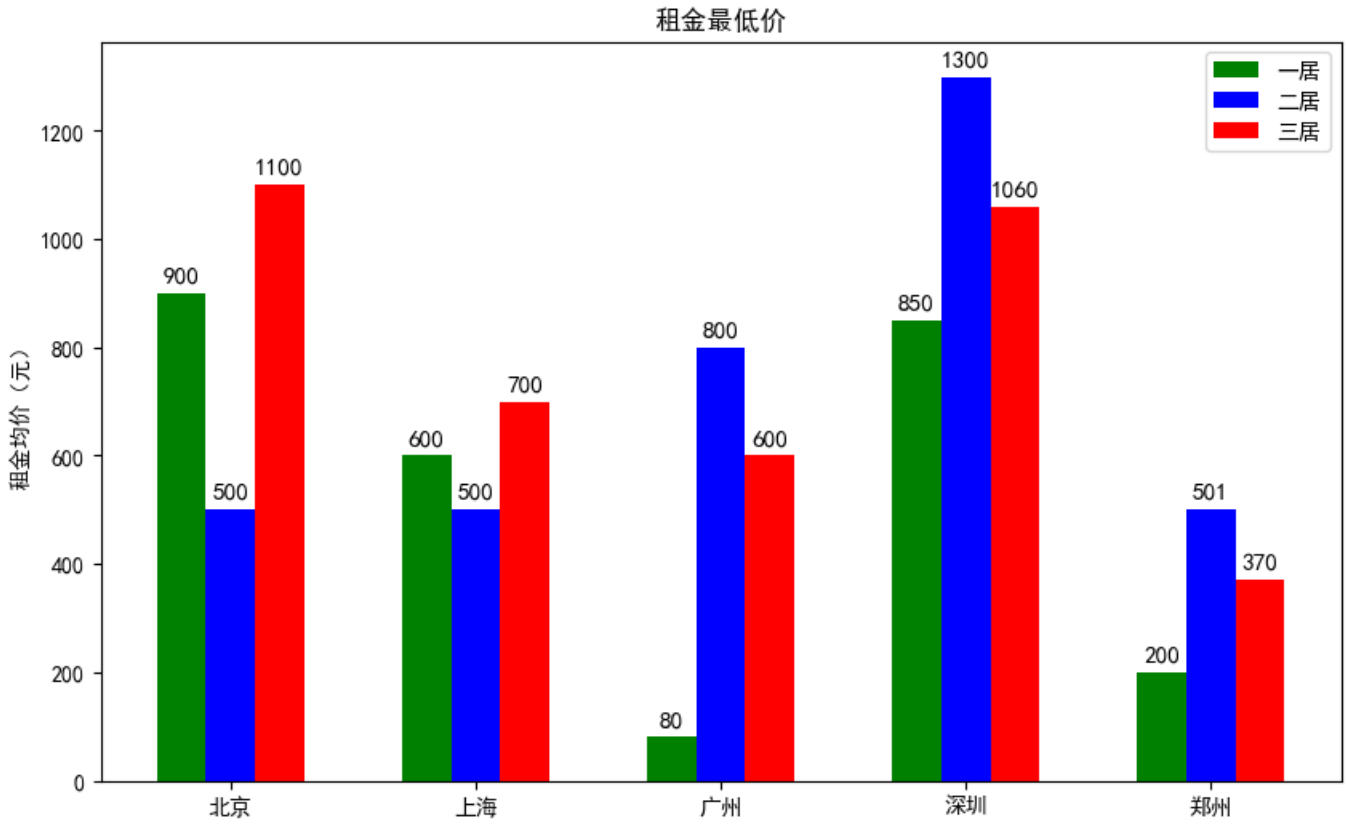
租金最低价
一居
二居
三居
租金均价（元）
0
200
400
600
800
1000
1200
900
500
1100
600
500
700
80
800
600
850
1300
1060
200
501
370
北京
上海
广州
深圳
郑州

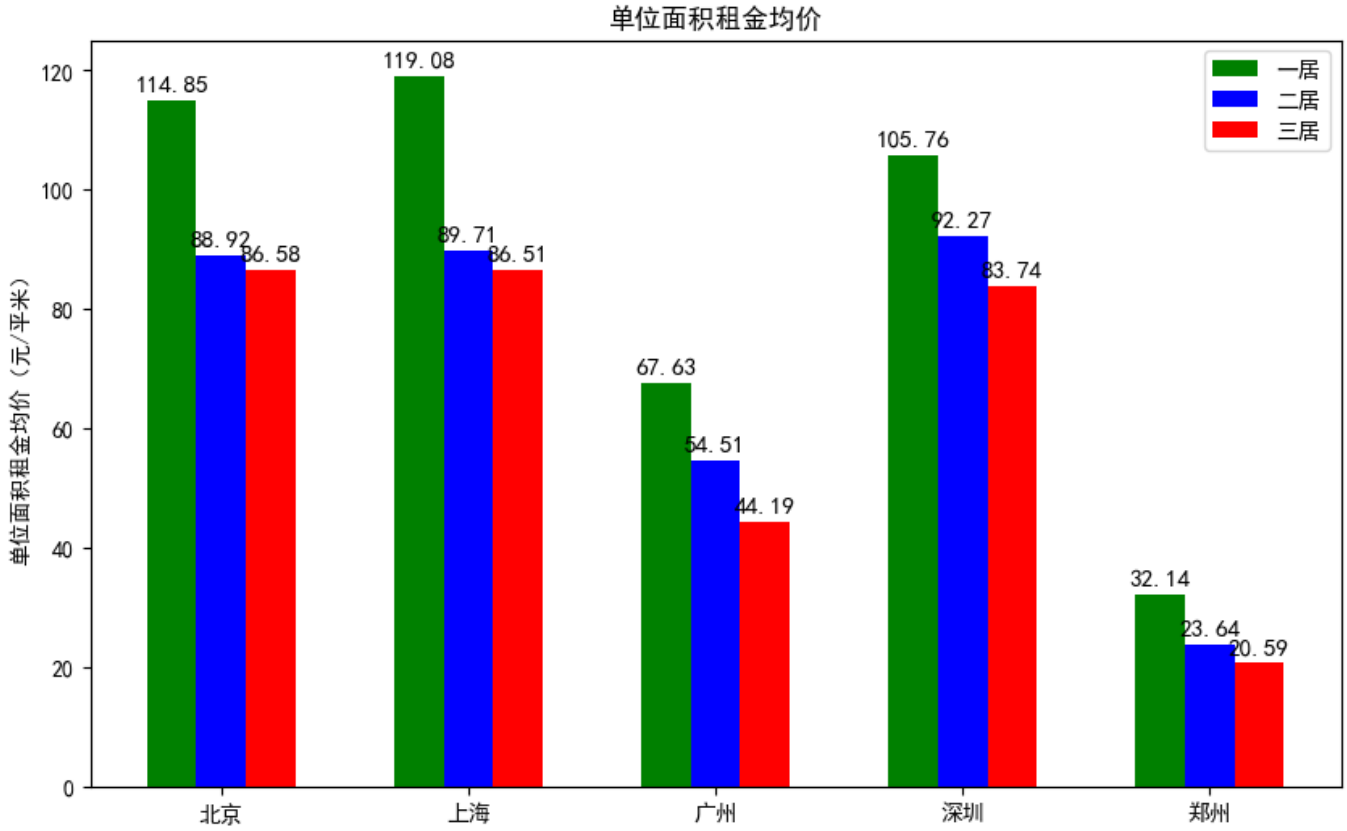
单位面积租金均价
一居
二居
三居
单位面积租金均价（元/平米）
0
20
40
60
80
100
120
114.85
88.92
86.58
119.08
89.71
86.51
67.63
54.51
44.19
105.76
92.27
83.74
32.14
23.64
20.59
北京
上海
广州
深圳
郑州

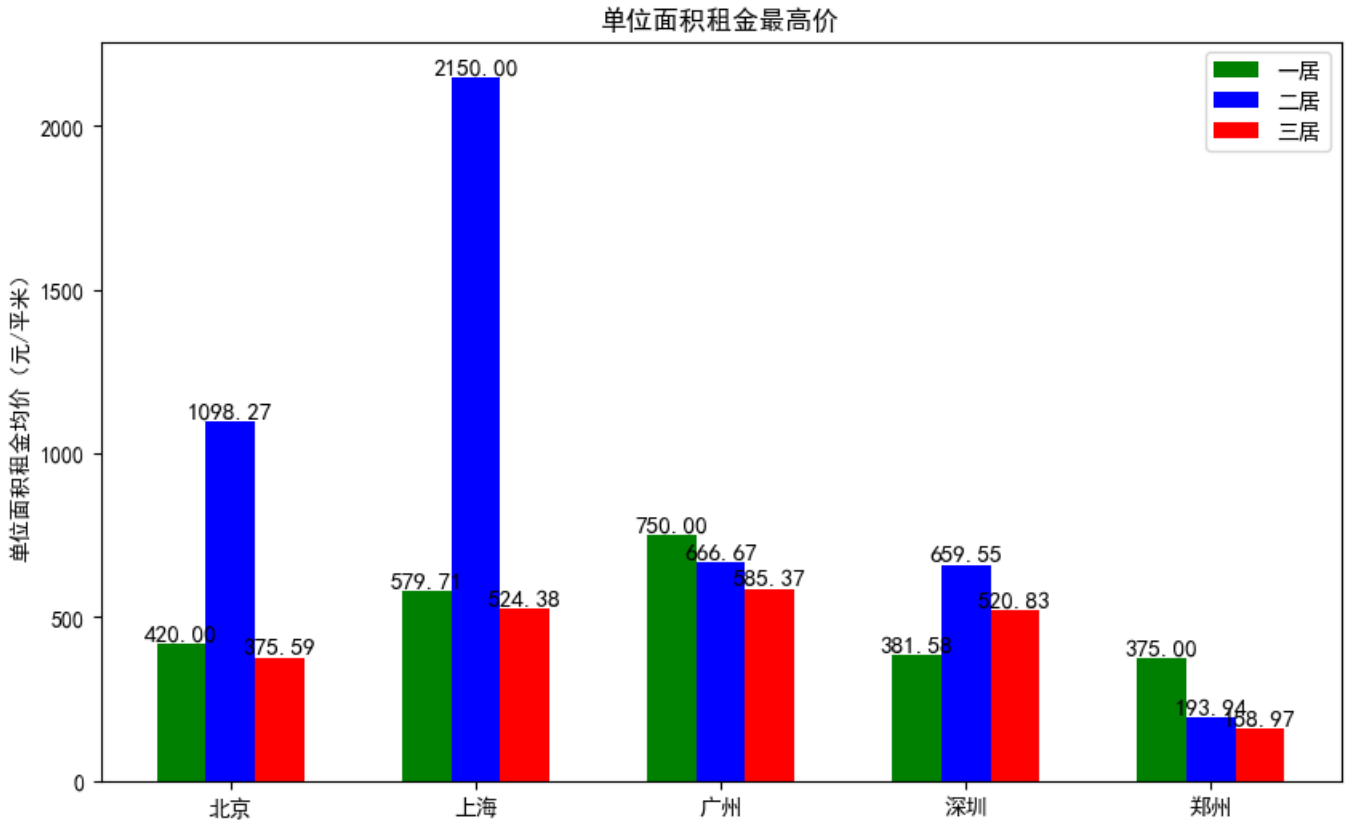
单位面积租金最高价
单位面积租金均价（元/平米）
一居
二居
三居
0
500
1000
1500
2000
420.00
1098.27
375.59
579.71
2150.00
524.38
750.00
666.67
585.37
381.58
659.55
520.83
375.00
193.94
158.97
北京
上海
广州
深圳
郑州

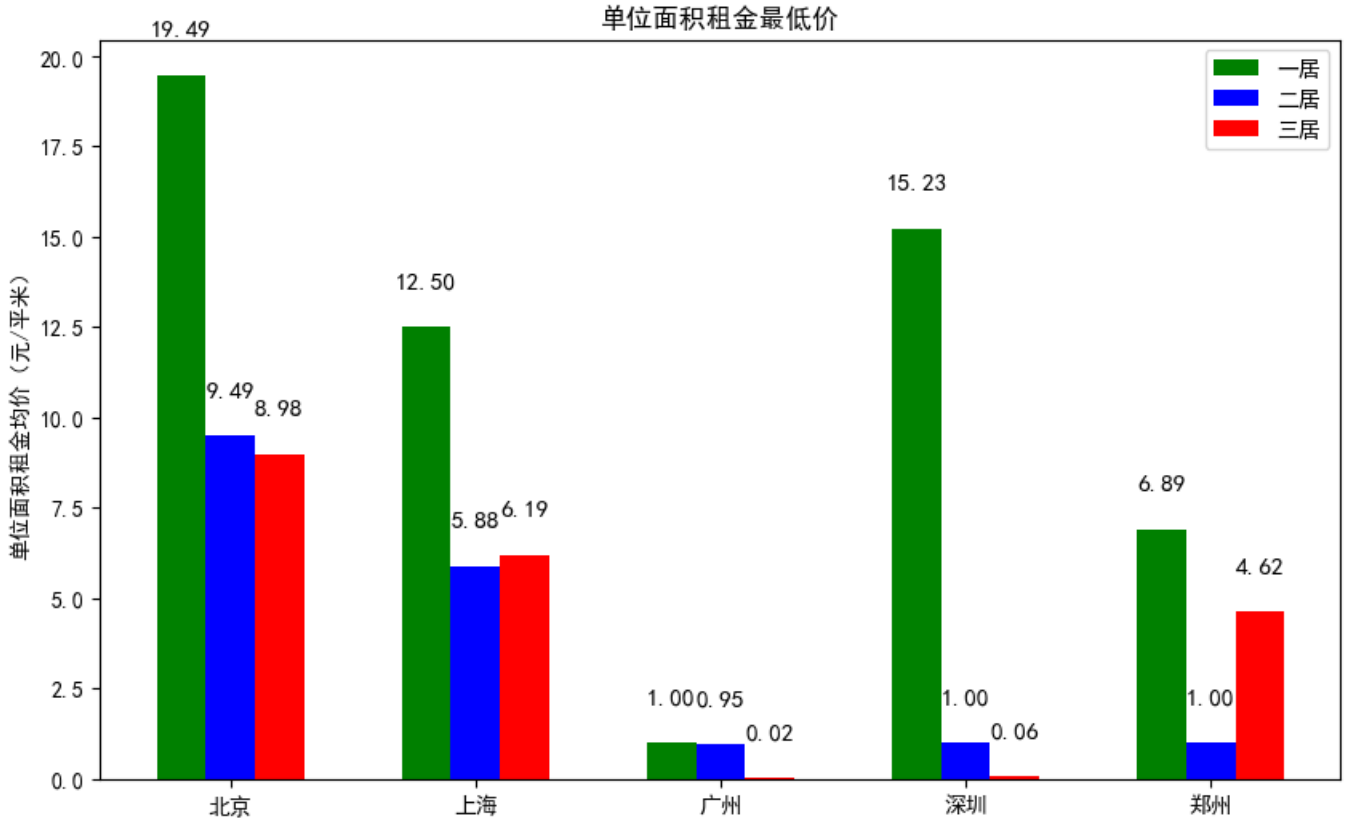
单位面积租金最低价
单位面积租金均价（元/平米）
一居
二居
三居
0.0
2.5
5.0
7.5
10.0
12.5
15.0
17.5
20.0
19.49
9.49
8.98
12.50
5.88
6.19
1.00
0.95
0.02
15.23
1.00
0.06
6.89
1.00
4.62
北京
上海
广州
深圳
郑州

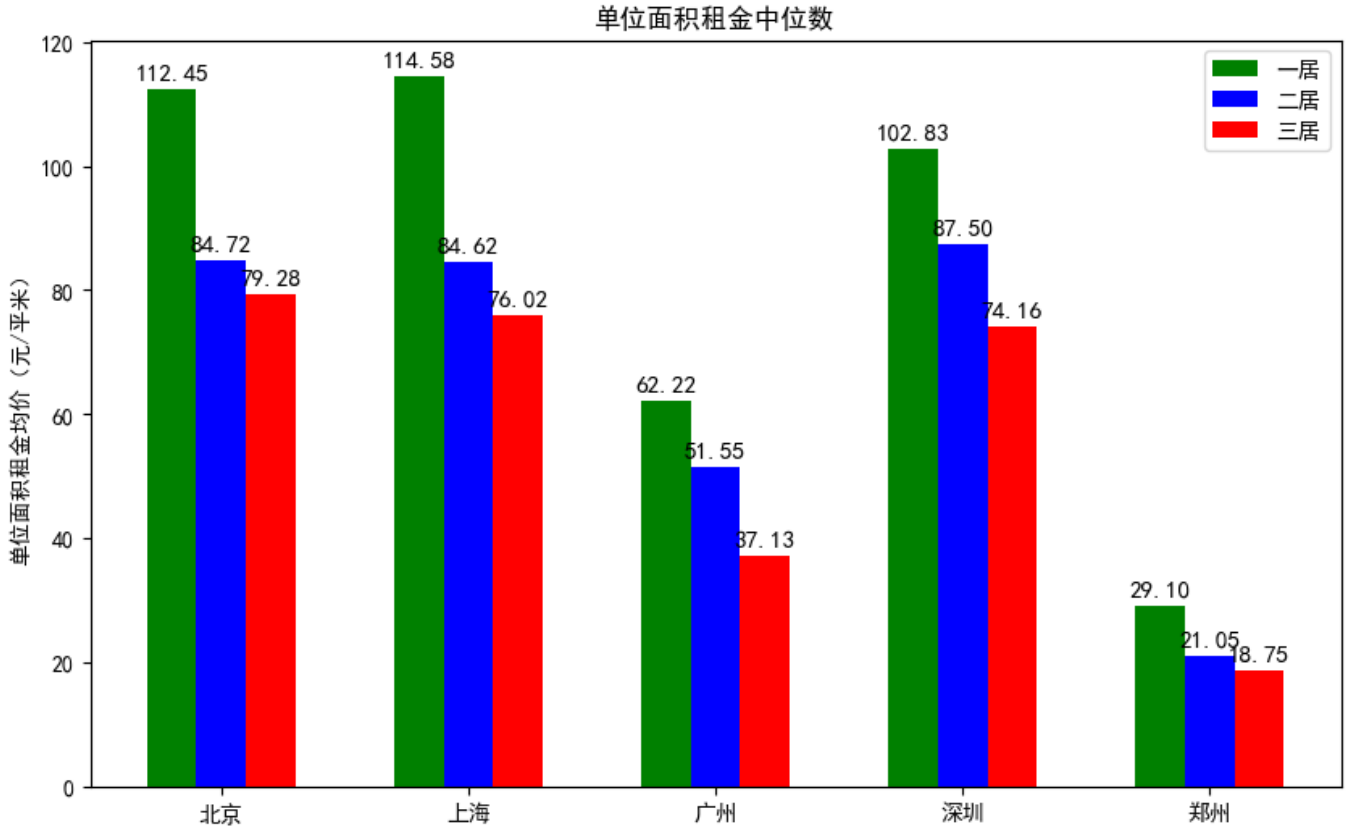

5. 板块均价比较

代码编写

与上面的代码类似,板块均价 同时部分代码如下

```
    plt.rcParams['font.sans-serif'] = ['SimHei']
for i in range(len(citynamelist)):
    plt.figure(figsize=(3,5))
    cityname=citynamelist[i]
    df=df_list[i]
    block_list=df["block"].unique()
    block_price_list=[]
    for block in block_list:
        block_price_list.append(df[df["block"]==block]["price"].mean())
    plt.boxplot(block_price_list)
    plt.title(citynamelist_chinese[i])
    plt.ylabel("均价(元/月)")
```

结果展示

以北京数据为例，展示一小部分

- 安定门,7562.777777777777
- 安贞,8072.0
- 朝阳门外,11015.08510638298
- 朝阳门内,9965.333333333334

- 崇文门,11040.795918367347

总的数据在下面的文件中

北京板块均价 上海板块均价 广州板块均价 深圳板块均价 郑州板块均价

这里采用散点图来表示，因为散点图能够很好的表示数据的分布情况，而且能够很好的表示数据的异常情况，比如上海的某个板块的均价就很高，这样的数据就很容易被发现。

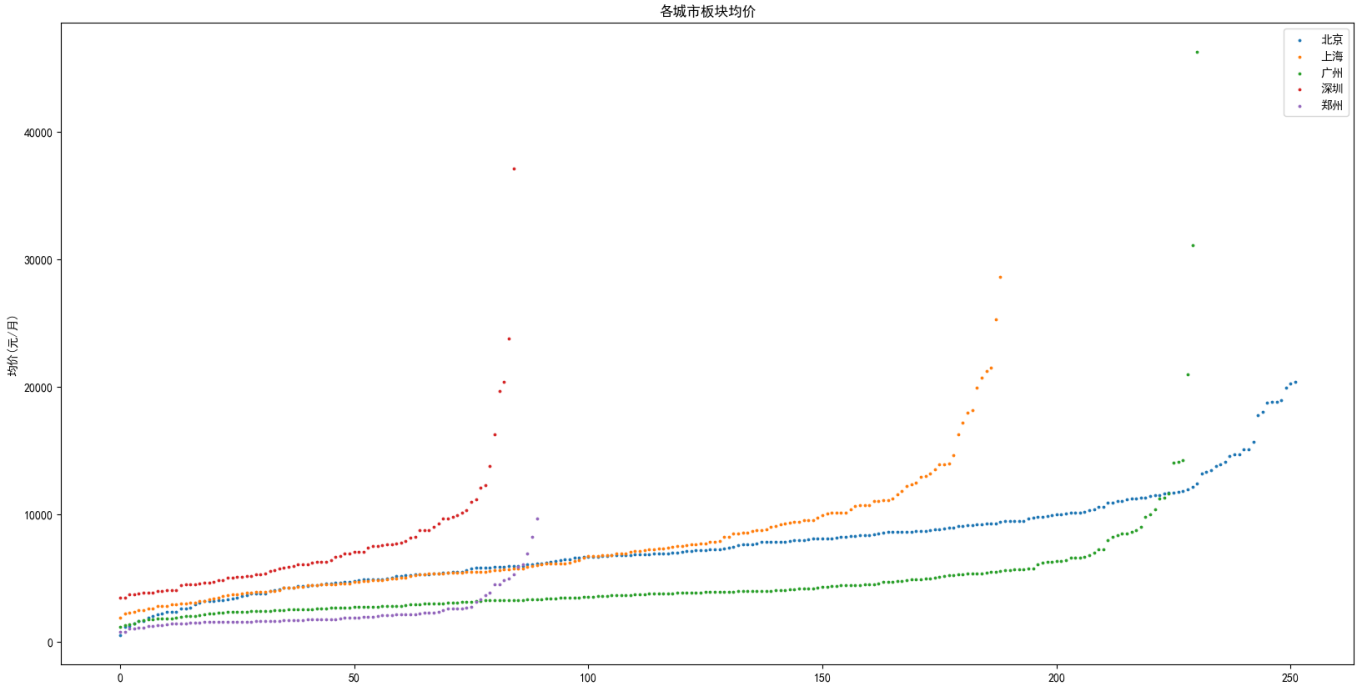

下面是各个城市的板块数量的散点图，为了能从中看出城市里不同板块中房子的数量，所以对数据进行了一些基本的归一化处理，然后再进行绘图。这里能从图上看出来，北京的板块数据相对分散，而上海的板块数据相对集中，这样的数据也能够很好的反映出城市的特点。

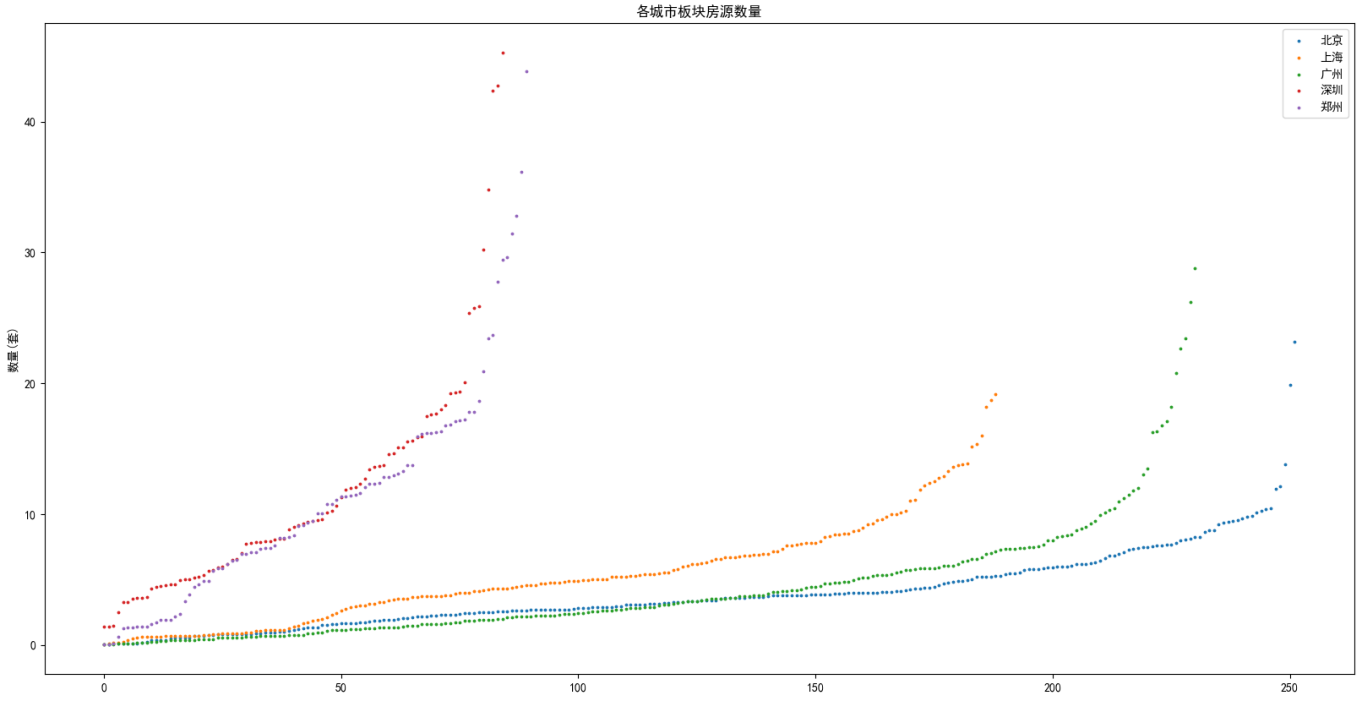

下面对五个城市的板块价格进行了箱线图的绘制，从图中能够看出每个城市板块价格的分布情况，以及每个城市板块价格的异常情况，比如上海的某个板块的均价就很高，这样的数据就很容易被发现同时也能直观地观察到方差等数据。

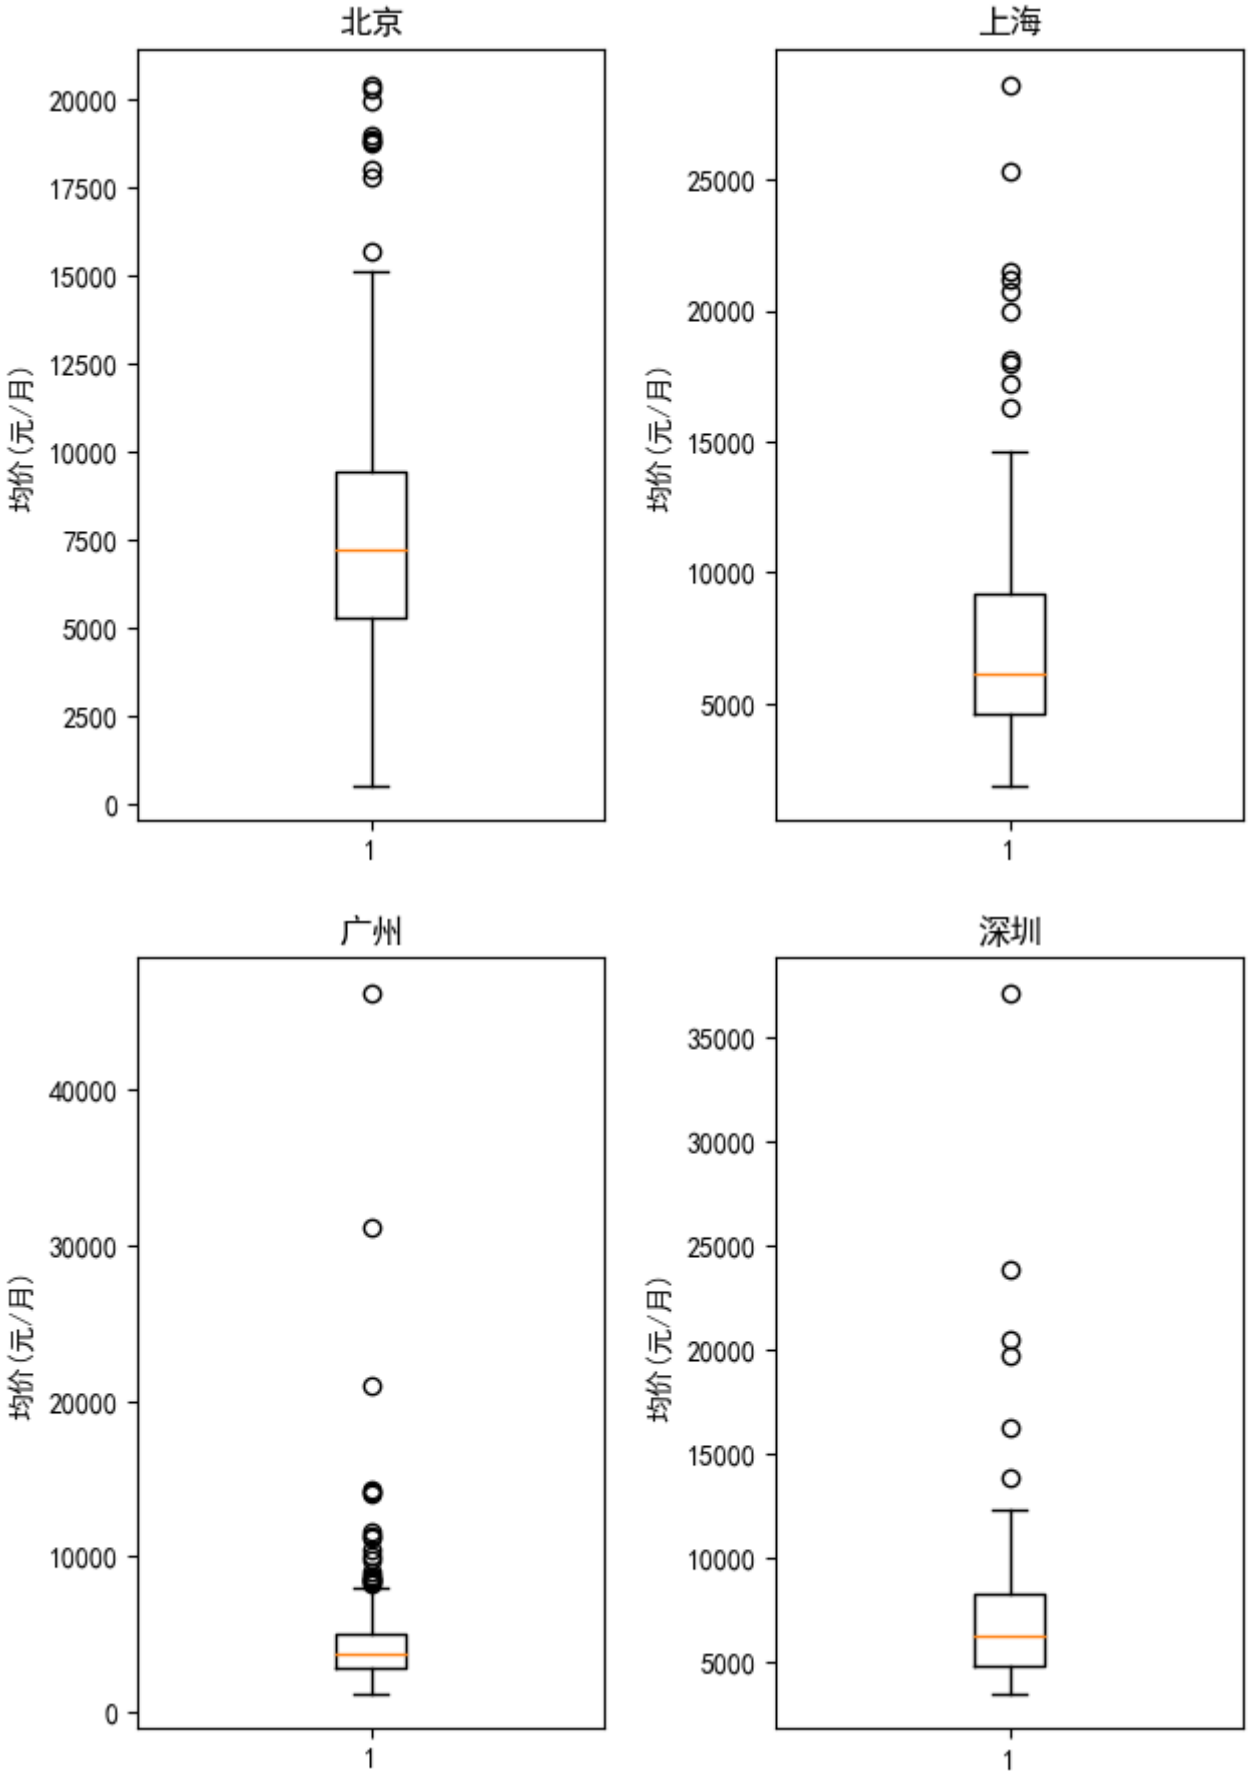

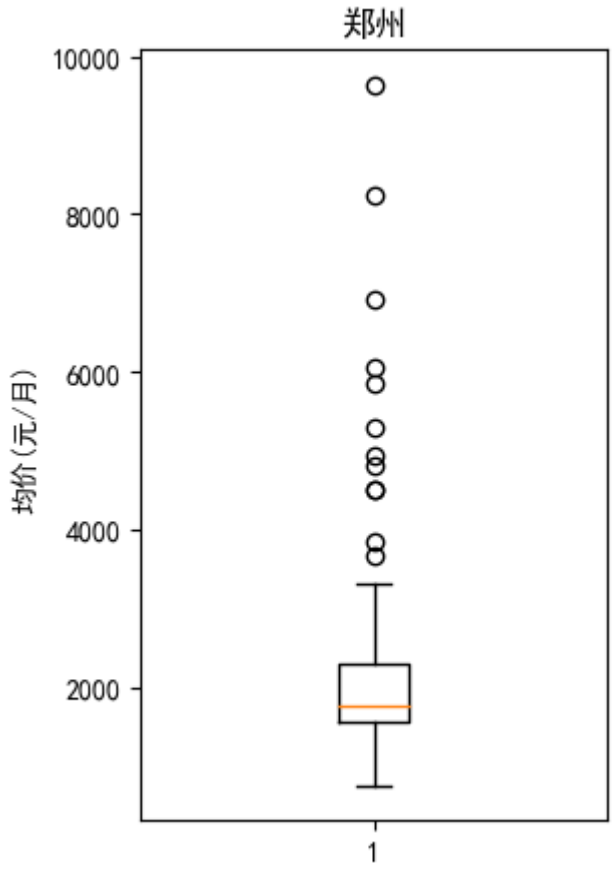

6. 朝向租金分布比较

比较各个城市不同朝向的单位面积租金分布情况，采用合适的图或表形式进行展示。哪个方向最高，哪个方向最低？各个城市是否一致？如果不一致，你认为原因是什么？

代码编写

与上面的代码类似,朝向租金分布总代码

同时部分代码如下

```
plt.rcParams['font.sans-serif'] = ['SimHei']
plt.rcParams['axes.unicode_minus'] = False
for i in range(len(citynamelist)):
    plt.figure(figsize=(6,6))

plt.pie(result[citynamelist_chinese[i]],labels=result[citynamelist_chinese[i]].ind
ex,autopct='%1.1f%%', shadow=True,explode=[0.1,0.1,0.1,0.1,0.1,0.1,0.1,0.1],
        radius=1.0)
    plt.title(citynamelist_chinese[i]+"的房源朝向分布")
    #plt.savefig(citynamelist_chinese[i]+"的房源朝向分布.png")
    plt.show()
```

下面是热力图的绘画

```
for i in range(len(citynamelist)):
    plt.figure(figsize=(10,6))
    print()
    sns.heatmap(df_list[i].groupby(["direct","name_chinese"])
["price"].mean().unstack(),annot=True,fmt='.0f',cmap='RdYlGn_r')
    plt.title(citynamelist_chinese[i]+"的房源朝向与板块的平均价格")
```

结果展示

下面五张图表示了各个城市中不同朝向的比例，能看到不同城市朝向分布有很大差别，也许是受气候风俗等影响

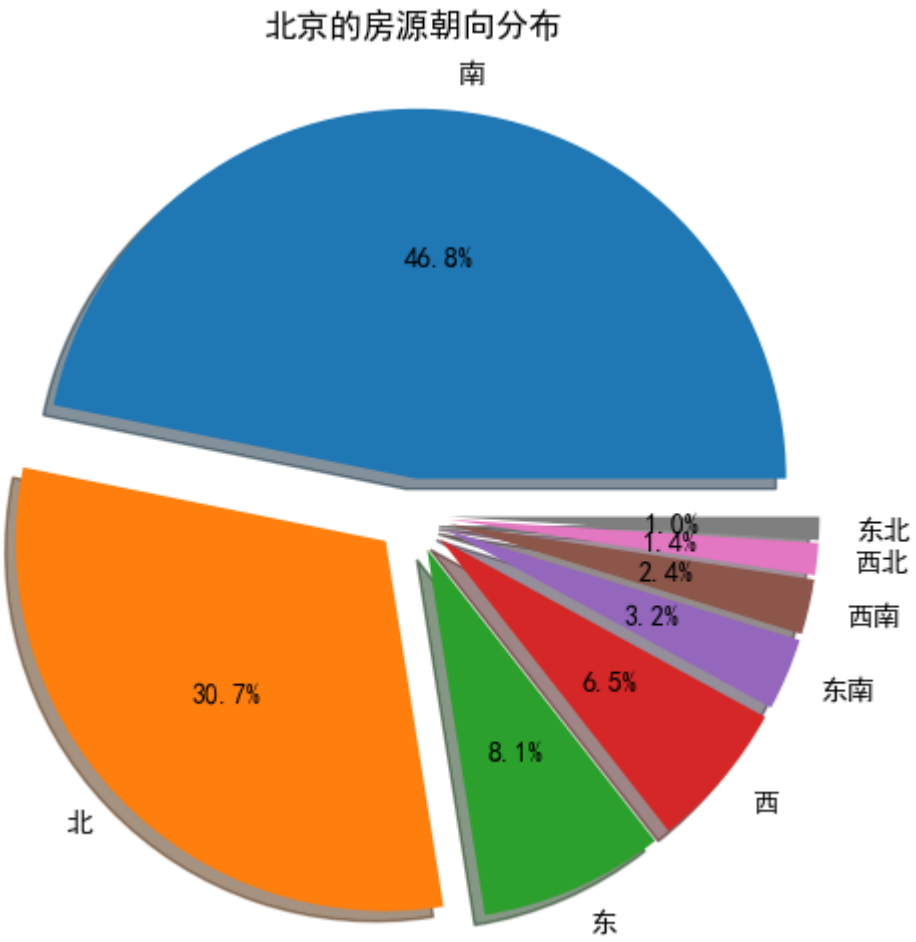
北京的房源朝向分布
南
46.8%
北
30.7%
东
8.1%
西
6.5%
东南
3.2%
西南
2.4%
西北
1.4%
东北
1.0%

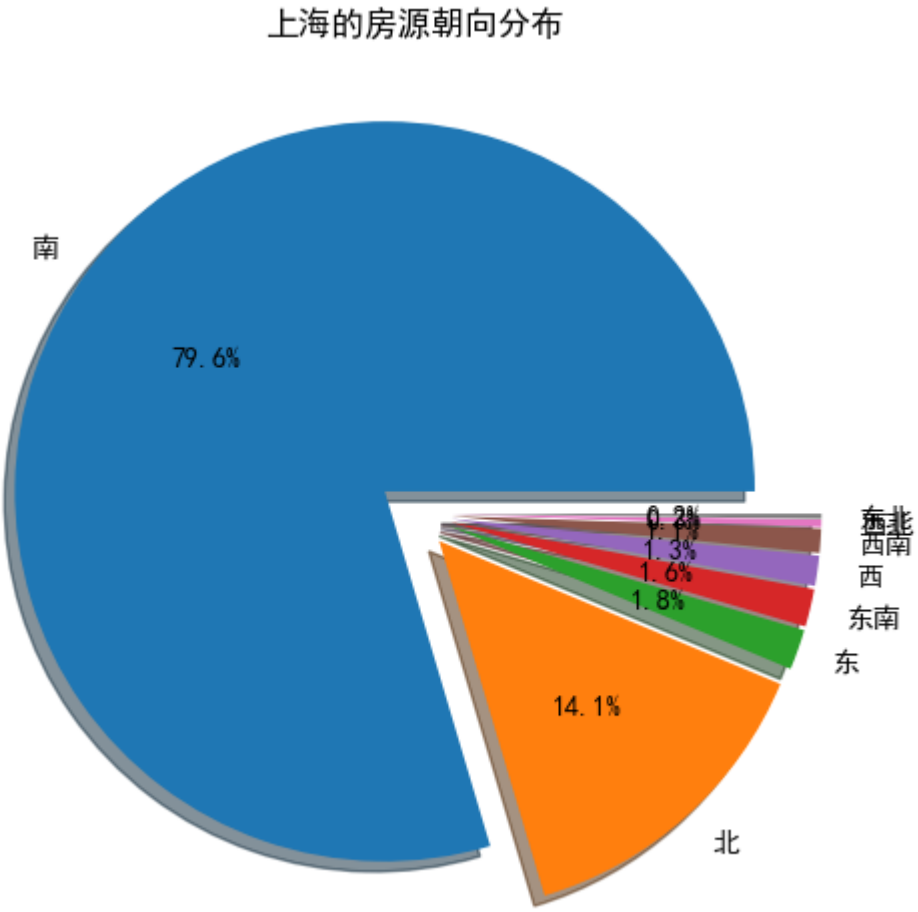
上海的房源朝向分布
南
79.6%
北
14.1%
东
1.8%
东南
1.6%
西
1.3%
西南
东北

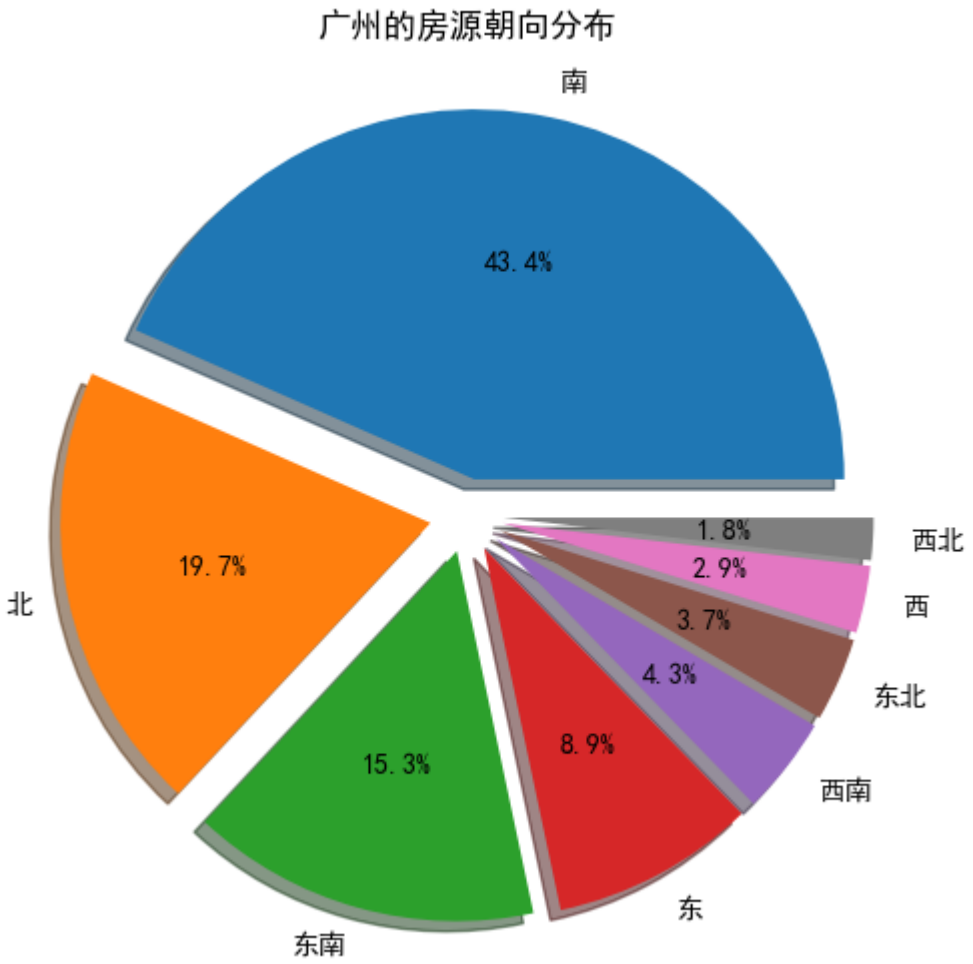
广州的房源朝向分布
南
43.4%
北
19.7%
东南
15.3%
东
8.9%
西南
4.3%
东北
3.7%
西
2.9%
西北
1.8%

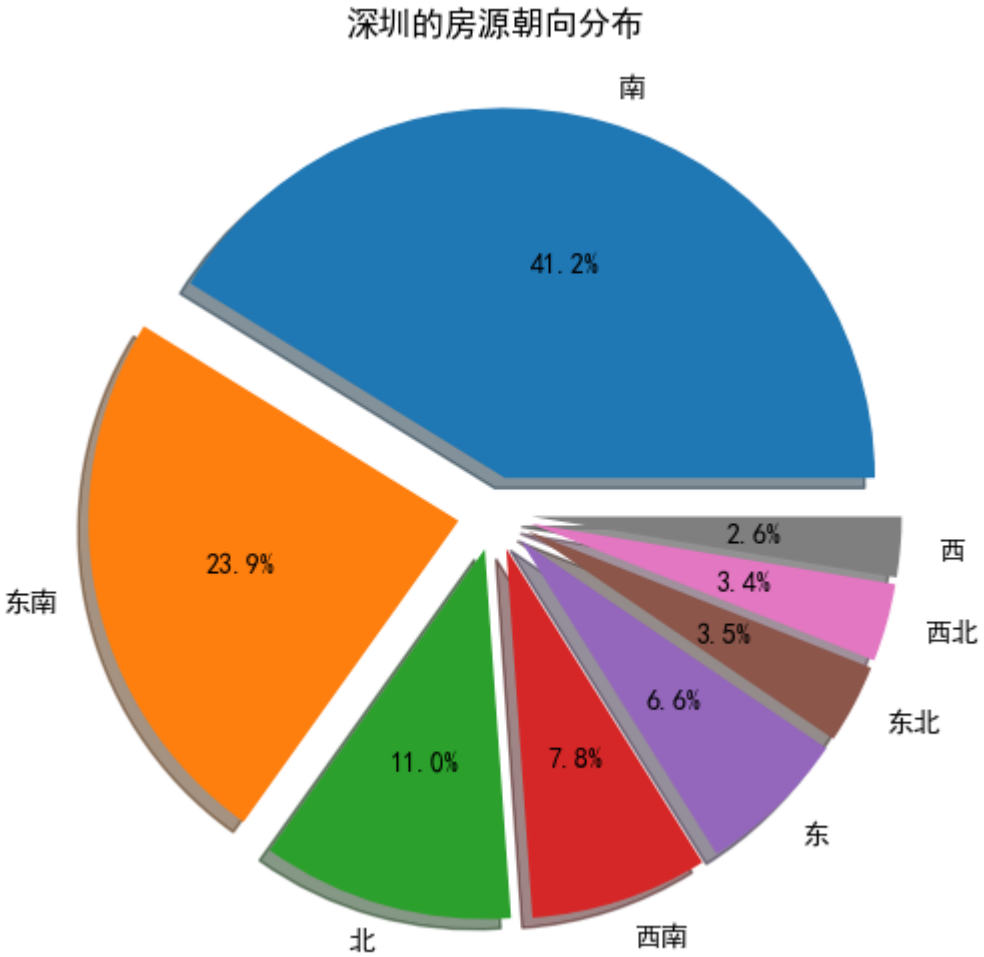
深圳的房源朝向分布
南
41.2%
东南
23.9%
北
11.0%
西南
7.8%
东
6.6%
东北
3.5%
西北
3.4%
西
2.6%

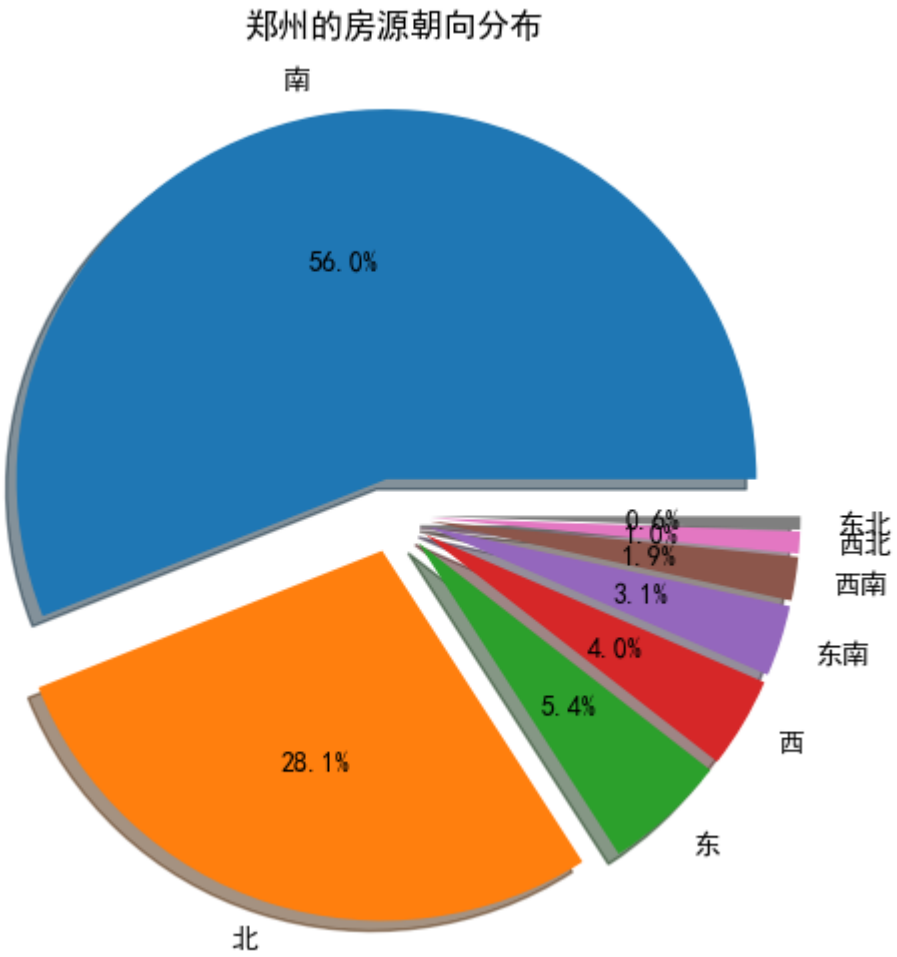

下面是城市和朝向的单位面积价格的热力图，颜色越深，价格越低，不同朝向对房价的影响不甚明显，数据中所有城市南向租金都相对较低，这里或许是因为南向的房子数据更多，不容易产生偏差导致的，

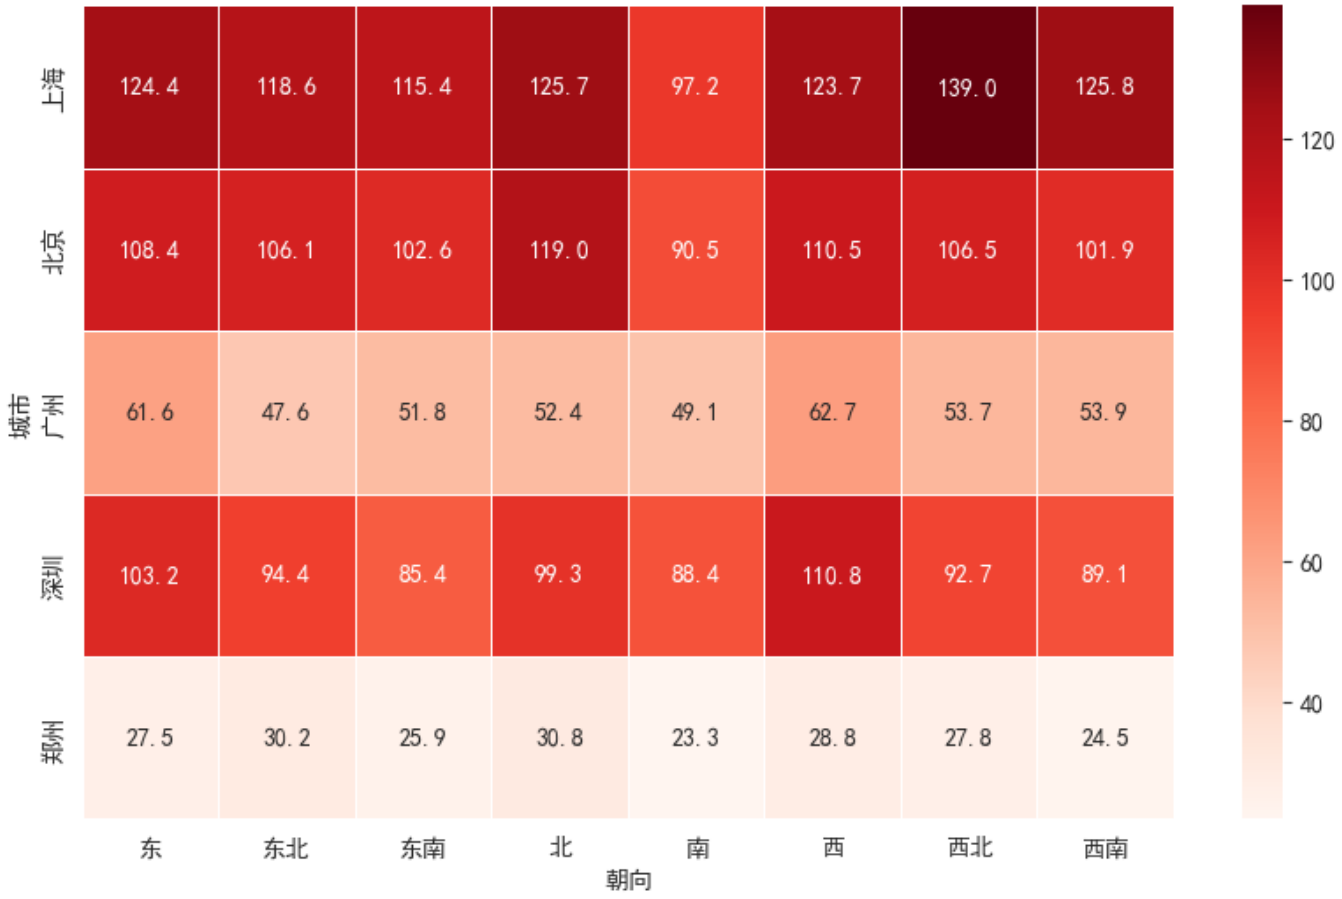

7. 城市平均工资与租金分布关系

查询各个城市的平均工资，分析并展示其和单位面积租金分布的关系。比较一下在哪个城市租房的负担最重？

数据获取

根据各地区人力资源和社会保障局所提供的数据

- 北京,135567 11297 数据来源
- 上海 136757 11396 数据来源
- 广州 130596 10883 数据来源
- 深圳 164754 13729 数据来源
- 郑州 93191 7766 数据来源

中国人均居住面积 41.76平方米 数据来源 中国人均住房支出占比 24% 数据来源

数据分析

代码编写

```
plt.hist(df_list[i]['price']/df_list[i]
['area'].astype('float64'),bins=100,label=citynamelist_chinese[i],alpha=0.5)
```

结果展示

下面是各个城市的平均工资和租金的数据图，放在一起方便对比，能看到深圳的收入最高，郑州的收入最低。但是感觉不够直观，因为深圳的房价也最高。所以后面又绘制了6个图来进行比较

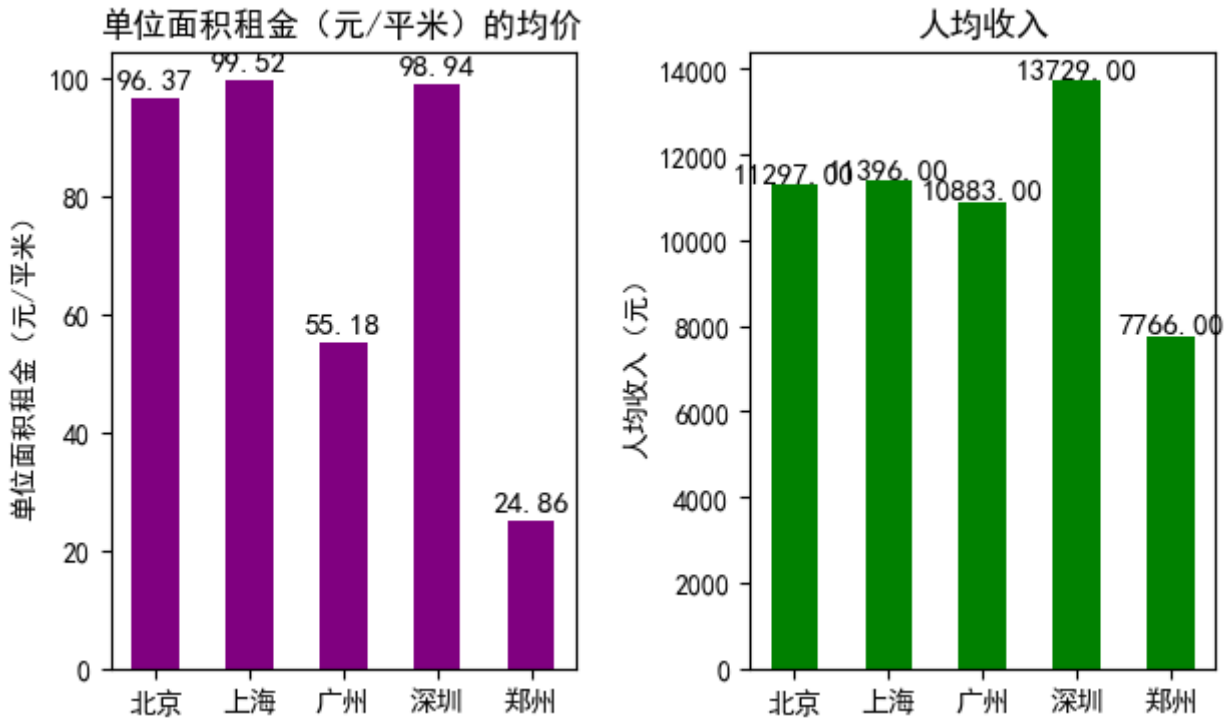

下面6个图是单位面积租金分布和平均工资对应租房月支出的对比图，其中计算逻辑为：中国人均住房支出占比*平均工资/人均居住面积，能看到北京和上海的租房负担最重，郑州的租房负担最轻，平均工资能租起绝大多数房子

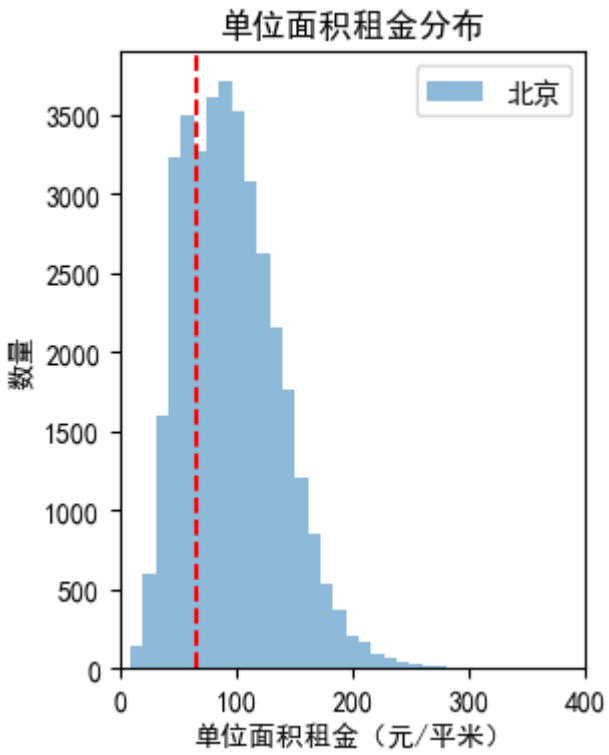
单位面积租金分布
北京
数量
单位面积租金（元/平米）
0
500
1000
1500
2000
2500
3000
3500
0
100
200
300
400

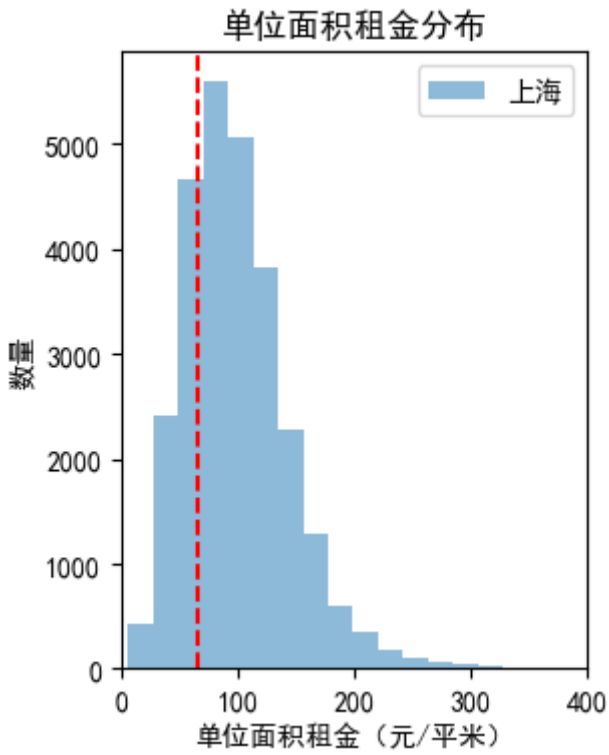
单位面积租金分布
上海
数量
单位面积租金（元/平米）
0
1000
2000
3000
4000
5000
0
100
200
300
400

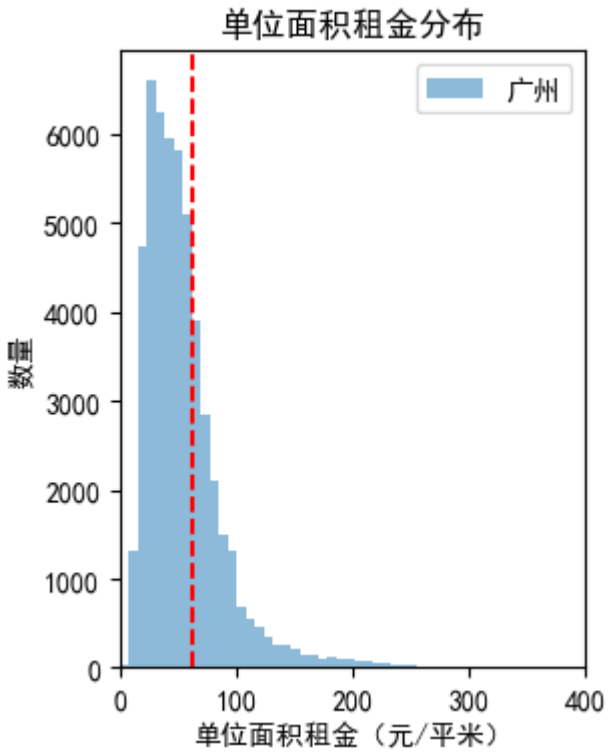
单位面积租金分布
广州
数量
单位面积租金（元/平米）
0
1000
2000
3000
4000
5000
6000
0
100
200
300
400

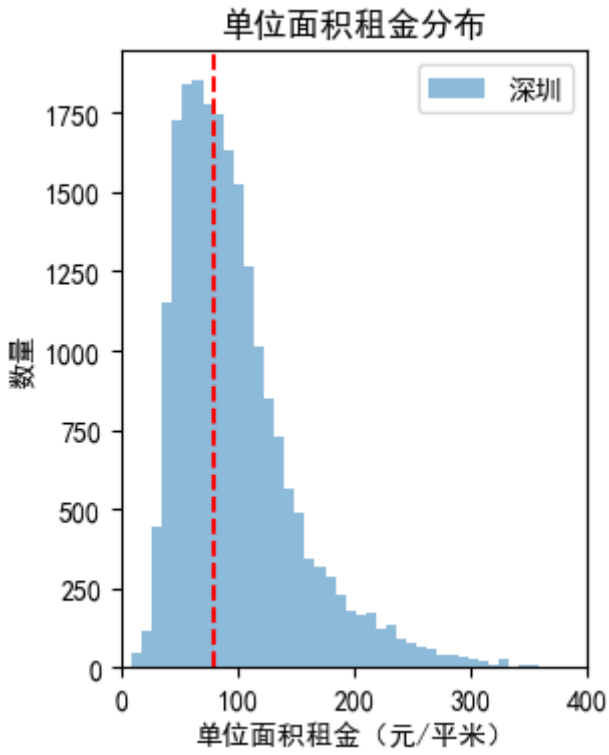
单位面积租金分布
深圳
数量
单位面积租金（元/平米）
0
250
500
750
1000
1250
1500
1750
0
100
200
300
400

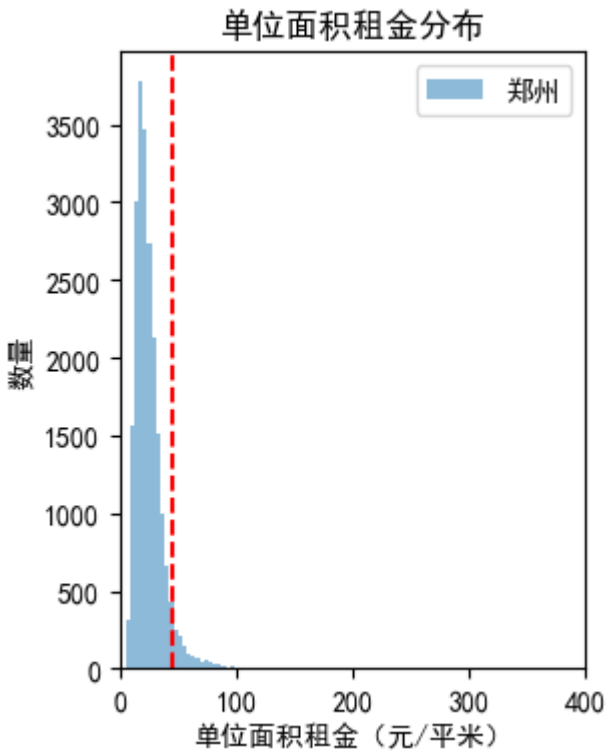

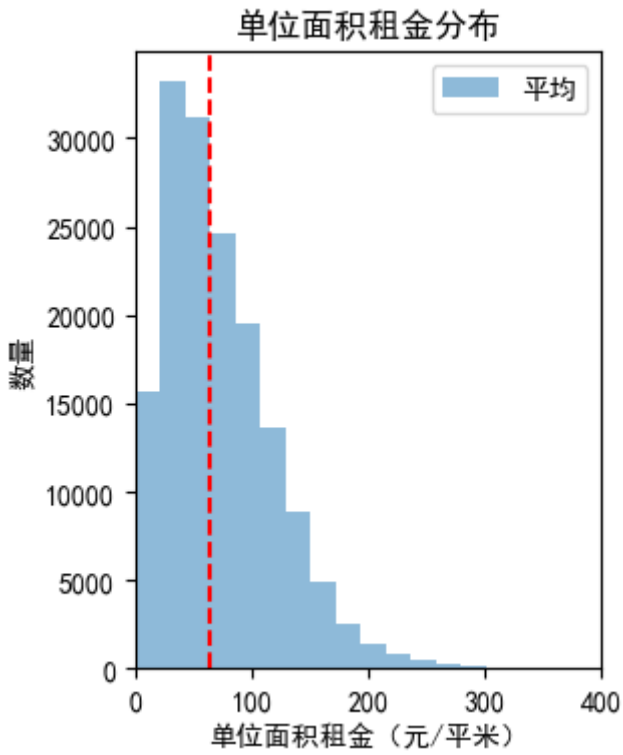

8. 与2022年数据对比

代码编写

因为2022年的租房数据格式是json，所以需要一个程序进行转化

```
import json
import csv
import os
file_list_chinese=['北京','上海','广州','深圳']
filename_list=
["BeijingHouseInfo.json","ShanghaiHouseInfo.json","GuangzhouHouseInfo.json","Shenz
henHouseInfo.json"]
file_list=["bj","sh","gz","sz"]
for i in range(4):
    with open(filename_list[i],'r',encoding='utf-8') as f:
        with open(file_list[i]+'.csv','w',encoding='utf-8',newline='') as f1:
            writer=csv.writer(f1)

writer.writerow(['name_chinese','block','house_type','direct','area','price'])
            for line in f.readlines():
                dic=json.loads(line)

writer.writerow([file_list_chinese[i],dic['district'],dic['layout'],dic['direction
'].split(" ")[0],dic['area'],dic['total_price']])
```

通过百分比变化率来衡量变化情况，考虑到如无特殊情况出现，所属板块，朝向，室型变化应该不大，所以这里将阈值设置较高，

```
plt.rcParams['font.sans-serif'] = ['SimHei']
for i in range(len(citynamelist)):
    for datatype in ["direct","house_type"]:
        for j in range(len(result_2022[i][datatype])):
            print(result_2022[i][datatype].index[j])
            if result_2022[i][datatype].index[j]=="nan":#做平均后出现非数了，就跳过
                continue
            #对比一下数据，差距大就输出
            if (abs(result_2022[i][datatype][result_2022[i][datatype].index[j]]-
result_2023[i][datatype][result_2022[i][datatype].index[j]])/result_2022[i]
[datatype][result_2022[i][datatype].index[j]])>0.2:
                print(result_2022[i][datatype][result_2022[i][datatype].index[j]])
                print(result_2023[i][datatype][result_2022[i][datatype].index[j]])

plt.bar([citynamelist_chinese[i]+"2022",citynamelist_chinese[i]+"2023"],
[result_2022[i][datatype][result_2022[i][datatype].index[j]],result_2023[i]
[datatype][result_2022[i][datatype].index[j]]])
                plt.title(citynamelist_chinese[i]+datatype+result_2022[i]
[datatype].index[j])
                plt.show()
```

完整代码

结果展示

首先是转化后的数据，这里只展示了北京的数据，其他城市的数据在对应的文件夹中

北京,安定门,1室1厅1卫,东,42.92,5200

其他数据列在下面

北京 上海 广州 深圳

结果分析

观察到数据变化较大的是深圳的户型，其中1室的房子数量变化超过了设定的阈值20%，而其他数据的变化都在阈值之内，查询资料后发现，深圳相关部门正努力改善居住环境，提高人均居住面积，详见关于进一步加大居

住用地供应的若干措施 ，所以一室租房数量下降也是正常的。

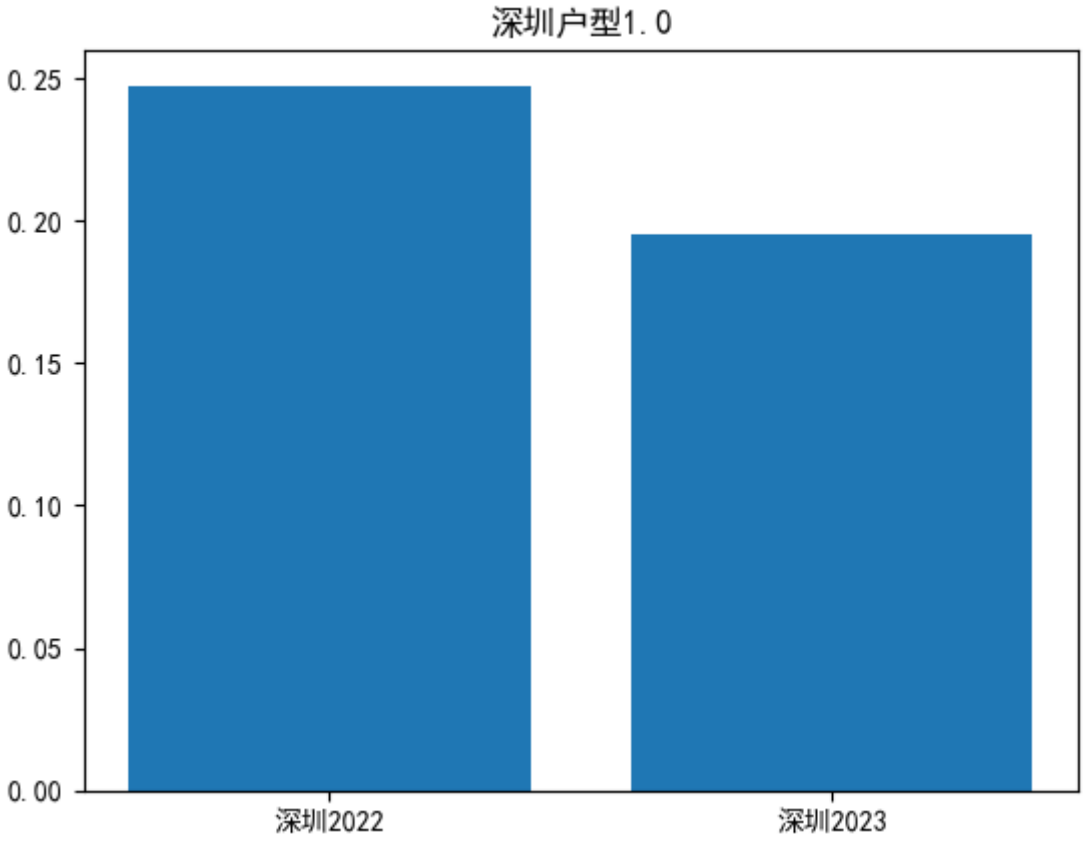

对于单位面积价格的对比，能看到四个城市房价均有所下降，其中深圳价格下降最快，广州价格基本没有变化，北京上海增长率位于深圳和广州之间。